



UNIVERSIDAD
COMPLUTENSE
MADRID



TRABAJO DE FIN DE MÁSTER

PREDICCIÓN DE LA ACCESIBILIDAD A LA VIVIENDA EN ESPAÑA MEDIANTE MACHINE LEARNING Y ANÁLISIS EXPLICATIVO DE LOS FACTORES DETERMINANTES

Alumno: Marcos Rodrigo Bermejo Arroyo
Máster: Big Data, Data Science & Artificial Intelligence

Curso académico 2025-26

Madrid, 17 de septiembre 2026

ÍNDICE

1.	Introducción	5
1.1.	Contexto y motivación del estudio	5
1.2.	Justificación y aportación del estudio	5
1.3.	Objetivos y preguntas de investigación	5
1.4.	Estructura del trabajo	6
2.	Construcción y análisis exploratorio del <i>dataset</i> (EDA)	6
2.1.	Fuentes, unidad de análisis y cobertura	6
2.2.	Definición y construcción del IAV	7
2.3.	Calidad y clasificación de las variables	8
2.4.	Evolución temporal y heterogeneidad territorial	9
2.5.	Patrones trimestrales y brecha de accesibilidad por sexo	9
3.	Formulación del problema y preparación de los datos	11
3.1.	Construcción del problema supervisado	11
3.2.	Feature engineering	11
3.2.1.	Disponibilidad real y creación de variables retardadas	11
3.3.	Estructura de la variabilidad del IAV	12
3.4.	Relación de los predictores con el objetivo	13
3.5.	Selección de variables	13
3.6.	Codificación y estrategia de validación temporal	14
4.	Modelización y evaluación	14
4.1.	Técnicas aplicadas y criterio de selección	15
4.2.	Dos formulaciones del problema de aprendizaje	15
4.3.	Significación estadística de las diferencias	16
4.4.	Optimización de hiperparámetros	17
4.5.	Bondades y debilidades de cada técnica	17
4.6.	Ajuste definitivo y evaluación sobre 2024	18
4.7.	Selección del modelo y respuesta a la inestabilidad	19
5.	Interpretación del modelo	20
5.1.	Consideraciones previas y concordancia entre modelos	20
5.2.	Aportación de cada bloque temático	21
5.3.	Refutación de la hipótesis sobre la presión turística	22
5.4.	Diferencias territoriales en la aportación del modelo	22
6.	Productivización	23
7.	Conclusiones, limitaciones y propuestas de mejora	23
7.1.	Conclusiones	23

7.2. Limitaciones y líneas de trabajo futuras	24
8. Bibliografía	25
Anexos	26
I. Planificación temporal	26
II. Licencias de uso de las fuentes de datos	27
III. Código de generación del <i>dataset</i> del proyecto	27
i. Generación del conjunto maestro	27
ii. Obtención del conjunto definitivo	27
IV. Bibliografía para el <i>dataset</i> maestro	28
V. App	29
VI. Figuras y tablas extra	34

ÍNDICE DE FIGURAS

Figura 1. Evolución trimestral del IAV (2015-2024)	9
Figura 2. Desviación del IAV respecto al promedio anual de cada provincia	10
Figura 3. Evolución del IAV según el salario por sexo	10
Figura 4. MAE medio de validación según la formulación del problema	16
Figura 5. Evolución trimestral del MAE sobre el conjunto de prueba (2024)	18
Figura 6. MAE de los modelos candidatos sobre conjunto de prueba (2024)	20
Figura 7. Concordancia (Spearman) entre las importancias de cada modelo	21
Figura 8. Ejecución del script	30
Figura 9. Pestaña superior de la app	30
Figura 10. Mapa de España geográfico y mosaico	30
Figura 11. Información del territorio seleccionado	31
Figura 12. Formulario del simulador con hipoteca	31
Figura 13. Supuestos hipotecarios editables	31
Figura 14. Resultado por territorio del simulador con hipoteca	32
Figura 15. Modalidad de compra al contado	32
Figura 16. Resultado por territorio del simulador con pago al contado	32
Figura 17. Control de variación del tipo de interés	33
Figura 18. Resultado de la simulación de tipos positivos de interés	33
Figura 19. Resultado de la simulación de tipos negativos de interés	34
Figura 20. Territorios con mayor y menor accesibilidad (2015-2024)	34
Figura 21. Variación del IAV entre 2015 y 2024 por territorio	35
Figura 22. Optimización de hiperparámetros	38

ÍNDICE DE TABLAS

Tabla 1. Valor tasado vs precio reconstruido (base 100)	7
Tabla 2. Información sobre las variables del dataset	8
Tabla 3. Diagrama de Gantt del tiempo dedicado al TFM	26
Tabla 4. Tabla de correlaciones de las predictoras con el objetivo	36
Tabla 5. VIF antes y después de la selección	37

Tabla 6. Pares de predictoras con correlación (Spearman) superior a 0,80	37
Tabla 7. Resultados formulación directa	37
Tabla 8. Resultados formulación de corrección	38
Tabla 9. Importancia relativa (%) de cada bloque temático por modelo	39

ÍNDICE DE SIGLAS

TFM	→	Trabajo de Fin de Máster
IAV	→	Índice de Accesibilidad a la Vivienda
ML	→	Machine Learning (aprendizaje automático)
INE	→	Instituto Nacional de Estadística
AEAT	→	Agencia Estatal de Administración Tributaria
IPV	→	Índice de Precios de Vivienda
EDA	→	Exploratory Data Analysis (Análisis exploratorio de datos)
KNN	→	K-Nearest Neighbors (k vecinos más próximos)
SVR	→	Support Vector Regression (regresión por vectores de soporte)
XGBoost	→	eXtreme Gradient Boosting (potenciación del gradiente extrema)
MLP	→	Multilayer Perceptron (perceptrón multicapa)
MAE	→	Mean Absolute Error (error absoluto medio)
MAPE	→	Mean Absolute Percentage Error (error porcentual absoluto medio)
RMSE	→	Root Mean Squared Error (raíz del error cuadrático medio)
R^2	→	Coeficiente de determinación
SHAP	→	SHapley Additive exPlanations (explicaciones aditivas de Shapley)
VIF	→	Variance Inflation Factor (factor de inflación de la varianza)
η^2	→	Eta cuadrado (proporción de varianza explicada por una variable categórica)
VUT	→	Vivienda de Uso Turístico

1. Introducción

1.1. Contexto y motivación del estudio

El acceso a la vivienda constituye uno de los principales retos económicos y sociales en España. En la última década, el mercado residencial ha experimentado un incremento sostenido de los precios. Muestra de ello es que, al cierre del cuarto trimestre de 2024, la tasa de variación interanual del Índice de Precios de Vivienda (IPV) alcanzó un 11,3 %, con ascensos del 12,3 % en obra nueva y del 11,1 % en vivienda de segunda mano [1]. Esta evolución ha contribuido a deteriorar la accesibilidad económica, ya que el crecimiento de los precios por encima de las rentas y el aumento de los costes de financiación han elevado el esfuerzo necesario para adquirir una vivienda.

Sin embargo, esta problemática no afecta de manera homogénea a todo el territorio. Según el Banco de España, el dinamismo residencial se ha visto impulsado por factores como la presión demográfica y la demanda de no residentes, frente a una oferta de obra nueva notablemente inelástica que ha incrementado los precios [2]. Dado que las condiciones demográficas, laborales, financieras y de producción de nuevas viviendas difieren sustancialmente entre provincias, las métricas agregadas a nivel nacional o autonómico tienden a enmascarar diferencias territoriales relevantes.

Para evaluar esta problemática, el análisis tradicional estudia de forma conjunta el precio del inmueble y los salarios. No obstante, estimar un indicador de accesibilidad utilizando sus propios componentes contemporáneos resultaría tautológico, pues el modelo se limitaría a reproducir una fórmula matemática. Por ello, el objetivo central de este Trabajo de Fin de Máster (TFM) es predecir la evolución futura del Índice de Accesibilidad a la Vivienda (IAV) provincial con un año de antelación, empleando únicamente información económica, demográfica, laboral, financiera y residencial disponible *ex ante*. Mediante el uso de técnicas de aprendizaje automático (*Machine Learning*, ML) combinadas con métodos de interpretabilidad, este trabajo busca evaluar la capacidad predictiva de dicho conjunto de variables e identificar los factores de mayor relevancia en la dinámica del mercado residencial.

1.2. Justificación y aportación del estudio

Una de las principales aportaciones de este TFM consiste en la construcción de un conjunto de datos propio, diseñado específicamente para analizar y predecir la accesibilidad a la vivienda en España. Su elaboración fue necesaria debido a la inexistencia de una única fuente que reuniera, con una cobertura temporal y territorial homogénea, los principales factores potencialmente relacionados con este fenómeno.

Para su construcción se recopiló información procedente de organismos oficiales, principalmente del Instituto Nacional de Estadística (INE), la Agencia Estatal de Administración Tributaria (AEAT), el Banco de España y el Ministerio de Vivienda y Agenda Urbana. El conjunto resultante reúne indicadores demográficos, laborales, económicos, financieros y residenciales que originalmente se encontraban dispersos entre distintas operaciones estadísticas.

La aportación del trabajo no se limita a recopilar esta información, sino que consiste en organizarla en una estructura provincial y trimestral adecuada para formular un verdadero problema de predicción. De este modo, la información disponible en cada trimestre podrá emplearse para anticipar la evolución del IAV provincial con un año de antelación, evitando que el modelo se limite a reproducir la fórmula del indicador.

1.3. Objetivos y preguntas de investigación

El objetivo principal de este TFM es desarrollar un sistema capaz de anticipar el IAV provincial con cuatro trimestres de antelación, empleando exclusivamente información disponible en el momento de realizar la predicción. Este objetivo general se concreta en cuatro objetivos específicos:

- 1) Construir un conjunto de datos provincial y trimestral que integre los determinantes económicos, demográficos, laborales, financieros y residenciales de la accesibilidad a la vivienda.

- 2) Comparar diferentes técnicas de aprendizaje automático y distintas formulaciones del problema, determinando su precisión mediante contrastes estadísticos que permitan afirmar si una mejora es real o atribuible al azar.
- 3) Interpretar qué factores resultan más relevantes en la evolución de la accesibilidad, distinguiendo en todo momento la asociación estadística de la relación causal.
- 4) Trasladar el modelo a una aplicación funcional, en la que se puedan introducir valores nuevos y obtener una predicción, de forma equivalente a una herramienta empresarial.

Estos objetivos se articulan en torno a tres preguntas de investigación:

- ¿Es posible anticipar la accesibilidad futura a la vivienda con la información disponible *ex ante*, y en qué medida se mejora una previsión ingenua que asumiera que la situación no cambia?
- ¿Qué factores territoriales explican que unas provincias se deterioren más deprisa que otras?
- ¿La elección de la técnica de predicción resulta determinante o, por el contrario, la forma de plantear el problema pesa más que el algoritmo escogido?

1.4. Estructura del trabajo

El presente TFM se organiza de la siguiente manera: tras la introducción previa, el capítulo 2 aborda la construcción y el análisis exploratorio, con especial atención a la definición y la reconstrucción del indicador. El capítulo 3 detalla la preparación de los datos y el diseño metodológico, donde se establece qué información está disponible en cada momento y cómo se evalúan los modelos. El capítulo 4 constituye el núcleo de la modelización porque compara las distintas técnicas, contrasta la significación de sus diferencias y selecciona la solución final. El capítulo 5 interpreta el modelo e identifica los factores más influyentes. El capítulo 6 describe la aplicación desarrollada para la puesta en uso del modelo. Finalmente, el capítulo 7 presenta las conclusiones con una orientación divulgativa, junto con las limitaciones del estudio y las líneas de trabajo futuras. El código completo, las tablas detalladas y los estudios complementarios se recogen en los anexos, disponibles junto con el conjunto de datos en el repositorio del proyecto ([TFM_MRBA](#)).

2. Construcción y análisis exploratorio del *dataset* (EDA)

Este capítulo describe cómo se construyó el conjunto de datos y qué revela un primer examen de su contenido. Esta fase, conocida como análisis exploratorio de datos (*Exploratory Data Analysis*, EDA), persigue entender la información disponible antes de modelizar: comprobar su calidad, caracterizar las variables y detectar los patrones que después guiarán las decisiones de predicción.

2.1. Fuentes, unidad de análisis y cobertura

El conjunto de datos se construyó mediante la integración de series estadísticas procedentes de diferentes organismos oficiales. El INE constituye la fuente principal de los indicadores demográficos, laborales, de precios y transacciones inmobiliarias [6]. Los salarios proceden de la AEAT. La información sobre financiación y crédito se obtuvo principalmente del Banco de España [3]. Por su parte, las estadísticas provenientes del Ministerio de Transportes y Movilidad Sostenible y del Ministerio de Vivienda y Agenda Urbana permitieron incorporar el valor tasado de la vivienda [4] y los visados de dirección de obra nueva [5], utilizados como indicador directo de la evolución de la oferta residencial.

Las fuentes originales presentaban distintas periodicidades y niveles de agregación. Para obtener una frecuencia común, las series mensuales se agregaron trimestralmente mediante sumas cuando representaban magnitudes acumulables, como las compraventas o los visados de obra nueva, y mediante medias cuando correspondían a índices, tipos o porcentajes. Las variables publicadas anualmente se asignaron a los cuatro trimestres del año de referencia. Esta homogeneización permitió integrar todas las series en una estructura común, aunque la disponibilidad efectiva y los retardos de publicación se tendrán en cuenta posteriormente al formular el problema predictivo.

El conjunto de datos se organiza como un panel, es decir, una tabla en la que cada fila combina un territorio con un momento del tiempo. En este caso, la unidad de análisis es la pareja formada por

una provincia y un trimestre. El conjunto reúne 52 territorios (las 50 provincias más Ceuta y Melilla) observados durante los 40 trimestres comprendidos entre el primer trimestre de 2015 y el cuarto de 2024, lo que arroja un total de 2.080 observaciones.

Para que las comparaciones entre territorios sean válidas, el panel debe estar equilibrado: cada provincia ha de disponer de información en los 40 trimestres, sin huecos ni duplicados. Se comprobó que así ocurre, de modo que ningún territorio aparece más veces que otro ni le faltan periodos. Esta propiedad es importante porque más adelante permitirá desplazar la variable objetivo en el tiempo dentro de cada provincia sin introducir irregularidades.

2.2. Definición y construcción del IAV

La variable objetivo, denominada *IAV_total*, es cuantitativa continua y representa los años de salario bruto medio necesarios para adquirir una vivienda de referencia de 80 m² en cada provincia. El indicador se obtiene mediante la siguiente expresión:

$$IAV_{p,t} = \frac{80 * (precio\ del\ m^2)_{p,t}}{(salario\ bruto\ medio\ anual)_{p,t}} = X(años)$$

donde *p* identifica la provincia y *t* el trimestre. Al ser un cociente entre dos cantidades expresadas en euros, la inflación se cancela por sí sola, de modo que no procede aplicar ningún ajuste adicional de precios.

El aspecto más delicado del indicador es qué precio emplear en el numerador. La fuente más natural, el valor tasado que publica el Ministerio, tiene el problema de que subestima de forma sistemática la evolución del mercado. Las tasaciones se apoyan en operaciones comparables anteriores y, por tanto, reaccionan con retraso a las subidas de precios. La consecuencia es llamativa entre 2015 y 2024, el valor tasado creció un 18,8 %, mientras que el IPV del INE, que es el índice oficial de referencia, subió un 51,2 % en ese mismo periodo. Un IAV calculado directamente con el valor tasado indicaría que la vivienda se ha vuelto más accesible en la última década, una conclusión difícil de sostener.

Para resolverlo se combinan ambas fuentes aprovechando la fortaleza de cada una. El valor tasado aporta el nivel de precios de cada provincia en 2015, fiable para comparar territorios entre sí, y el IPV aporta la evolución posterior, que es la magnitud oficial:

$$(precio\ del\ m^2)_{p,t} = (valor\ tasado)_{p,2015} * \left(\frac{IPV_{p,t}}{IPV_{p,2015}} \right)$$

Esta técnica, habitual en la elaboración de índices, se conoce como encadenamiento. Tiene una limitación que conviene declarar: el IPV se publica por comunidad autónoma, no por provincia, de modo que las provincias de una misma comunidad comparten la tasa de variación, aunque conservan niveles de partida distintos. El detalle año a año de ambas series se recoge en la Tabla 1.

Valor tasado (2015 = 100)		Precio reconstruido (2015 = 100)
año		
2015	100.000	100.000
2016	100.400	103.000
2017	101.300	107.000
2018	102.600	112.600
2019	104.500	118.000
2020	103.500	120.700
2021	105.200	125.300
2022	109.400	134.400
2023	113.100	139.500
2024	118.800	151.200

Tabla 1. Valor tasado vs precio reconstruido (base 100)

Con esta reconstrucción, el IAV medio del panel es de 5,835 años de salario, con una mediana de 5,447 y valores que van desde los 3,57 años de la provincia más accesible hasta los 11,74 de la

menos accesible. Ese amplio recorrido anticipa la fuerte desigualdad territorial que se analiza más adelante.

2.3. Calidad y clasificación de las variables

El *dataset* definitivo está compuesto por 37 variables. Además de la variable objetivo (*IAV_total*) y de los identificadores de territorio y periodo, hay 25 variables predictoras candidatas, es decir, factores que podrían ayudar a anticipar la accesibilidad, se denominan candidatas porque su inclusión definitiva en los modelos dependerá de los filtros que se aplican en el capítulo 3. Estas últimas se agrupan en seis bloques temáticos que se mantendrán durante todo el trabajo, ya que serán la unidad de análisis en el estudio de interpretabilidad del capítulo 5: demografía y hogares (8 variables), mercado laboral y rentas (6), mercado residencial y oferta (5), entorno económico (2), financiación (2) y presión turística (2). La Tabla 2 recoge la descripción completa de cada variable, su bloque, su unidad y su papel en el análisis.

Clasificación	Nº	Variable	Descripción	Tipo de valor	Nivel de desagregación	Uso
Identificadores	4	codigo_provincia	Código numérico del territorio	Entero	Identificador	Identificador
		comunidad_autonoma	Comunidad autónoma	Categorico	Identificador	Identificador
		periodo	Año y trimestre de la observación	Categorico	Identificador	Identificador
		provincia	Provincia o ciudad autónoma	Categorico	Identificador	Identificador
Demografía y hogares	8	pct_18_34	Población de entre 18 y 34 años	%	Provincial	Predictora
		pct_35_64	Población de entre 35 y 64 años	%	Provincial	Predictora
		pct_65_mas	Población de 65 años o más	%	Provincial	Predictora
		pct_hogares_unipersonales	Proporción de hogares unipersonales	%	Provincial	Predictora
		pct_poblacion_espanola	Proporción de población de nacionalidad española	%	Provincial	Predictora
		poblacion_total	Población total del territorio	Entero	Provincial	Predictora
		tamano_medio_hogar	Número medio de personas por hogar	Decimal	Provincial	Predictora
		tasa_migracion_neta_exterior_por_1000	Saldo migratorio exterior por cada 1.000 habitantes	Tasa	Provincial	Predictora
Mercado laboral y rentas	8	renta_mediana_por_unidad_consumo_eu	Renta mediana por unidad de consumo	Euros	Provincial	Predictora
		renta_neta_medio_por_hogar_eur	Renta neta media por hogar	Euros	Provincial	Predictora
		salario_medio_anual_euros_hombre	Salario bruto medio anual de los hombres	Euros	Provincial	No predictora
		salario_medio_anual_euros_mujer	Salario bruto medio anual de las mujeres	Euros	Provincial	No predictora
		salario_medio_anual_euros_total	Salario bruto medio anual	Euros	Provincial	Predictora
		tasa_actividad_pct_total	Tasa de actividad	%	Provincial	Predictora
		tasa_empleo_pct_total	Tasa de empleo	%	Provincial	Predictora
		tasa_paro_pct_total	Tasa de paro	%	Provincial	Predictora
Entorno económico	2	indice_costes_construccion	Índice de costes de construcción	Índice	Nacional	Predictora
		indice_precios_consumo_base_2015	Índice de precios al consumo provincial, base 2015 = 100	Índice	Provincial	Predictora
Financiación	2	importe_medio_hipoteca_vivienda_eur	Importe medio de las hipotecas sobre vivienda	Euros	Provincial	Predictora
		tipo_interes_prestamos_vivienda_pct	Tipo de interés de los préstamos para vivienda	%	Nacional	Predictora
Mercado residencial y oferta	5	compraventas_por_1000_hab	Compraventas trimestrales por cada 1.000 habitantes	Tasa	Provincial	Predictora
		ipv_general	Índice de precios de vivienda de la comunidad autónoma	Índice	Autonómico	Predictora
		pct_compraventas_vivienda_nueva	Proporción de compraventas de vivienda nueva	%	Provincial	Predictora
		valor_tasado_m2	Valor tasado medio de la vivienda	Euros/m ²	Provincial	Predictora
		visados_obra_nueva_por_1000_hab	Visados de obra nueva por cada 1.000 habitantes	Tasa	Provincial	Predictora
Presión turística	2	pernoctaciones_por_habitante	Pernoctaciones hoteleras por habitante	Tasa	Provincial	Predictora
		plazas_hoteleras_por_1000_hab	Plazas hoteleras por cada 1.000 habitantes	Tasa	Provincial	Predictora
Control de calidad	1	valores_arrastrados	Indica si la observación usa series anuales propagadas.	Binario	No aplica	Control
Variables derivadas	4	IAV_hombre	IAV calculado con el salario masculino	Años de	Provincial	No predictora
		IAV_mujer	IAV calculado con el salario femenino	Años de	Provincial	No predictora
		brecha_iav_absoluta	Diferencia entre el IAV femenino y el masculino	Años de	Provincial	No predictora
		precio_m2_mercado	Precio de mercado reanclado con el IPV del INE	Euros/m ²	Provincial	No predictora
Variable objetivo	1	IAV_total	Años de salario necesarios para adquirir una vivienda de 80 m ²	Años de salario	Provincial	No predictora

Tabla 2. Información sobre las variables del dataset

Junto a esa clasificación temática, cada variable se caracteriza además por su nivel de desagregación territorial, un atributo que resultará decisivo para interpretar los resultados. Una variable puede ser provincial (toma un valor distinto en cada provincia), autonómica (comparte valor dentro de cada comunidad) o nacional (un único valor para toda España en cada trimestre). La razón de distinguirlas es intuitiva: una variable que vale lo mismo en toda España no puede explicar por qué un territorio es más caro que otro, solo aporta un factor común que sube o baja para todos a la vez. En el conjunto final, 22 de las 25 predictoras son provinciales, una es autonómica (el IPV) y solo dos son nacionales (el tipo de interés hipotecario y el índice de costes de construcción). Esta composición es una decisión de diseño que se justifica en el capítulo 3.

El análisis descriptivo de las variables reveló que las magnitudes ligadas al tamaño del territorio (la población, las compraventas o los visados de obra nueva) presentan distribuciones muy asimétricas, porque unas pocas provincias concentran gran parte de la actividad. Por ello, en la

construcción del conjunto estas cantidades se expresaron como tasas por cada 1.000 habitantes, lo que las hace comparables entre territorios de distinto tamaño.

2.4. Evolución temporal y heterogeneidad territorial

El análisis de la evolución del IAV confirma el deterioro de la accesibilidad. El índice medio provincial pasó de 5,470 años de salario en 2015 a 6,192 en 2024, un incremento del 13,186 %. La subida fue además sostenida, como se puede apreciar en la Figura 1, en la que el indicador crece de forma continuada, con solo dos retrocesos interanuales de escasa magnitud, y que dentro de cada año dibuja un patrón regular de dientes de sierra que se examina en el apartado 2.5.




Figura 1. Evolución trimestral del IAV (2015-2024)

Esta evolución debe interpretarse como la correspondiente a la provincia media no ponderada, ya que todas las provincias recibieron el mismo peso con independencia de su población. Por tanto, el incremento observado no representó directamente un deterioro equivalente de la accesibilidad agregada del conjunto de España.

Con respecto a la evolución territorial, se observaron diferencias elevadas entre provincias. Los menores valores medios del IAV se registraron en Toledo, Ciudad Real, Teruel, Lugo y León, mientras que los valores más elevados correspondieron a Illes Balears, Gipuzkoa, Madrid, Málaga y Barcelona. En consecuencia, la accesibilidad residencial resultó claramente más desfavorable en algunas de las provincias con mayor presión demográfica que en buena parte de las provincias del interior (véase la Figura 20 del anexo).

La evolución entre 2015 y 2024 depara además un resultado inesperado. Aunque el indicador empeoró en 46 de los 52 territorios, los dos mayores deterioros del periodo no corresponden a las grandes capitales, sino a Ceuta y Melilla, con incrementos del 49,936 % y del 47,312 %, respectivamente. Ambas ciudades autónomas partían de posiciones intermedias en 2015 y cierran el periodo entre las menos accesibles. Se trata de territorios con una oferta residencial muy limitada por su reducida extensión, donde cualquier tensión de demanda se traslada al precio con especial intensidad. Madrid ocupa el tercer lugar, con un aumento del 36,379 %. En el extremo opuesto, las seis provincias donde la accesibilidad mejoró se concentran en Extremadura y Castilla-La Mancha (el detalle de la variación en los 52 territorios se recoge en la Figura 21 del anexo).

Esta dispersión tiene una implicación directa para la modelización, buena parte de la variabilidad del IAV es estructural y atribuible al territorio. Como se verá en el capítulo 3, saber en qué provincia se encuentra una observación explica casi por completo su nivel de accesibilidad, un hecho que condiciona toda la estrategia de predicción.

2.5. Patrones trimestrales y brecha de accesibilidad por sexo

El apartado cierra con dos análisis complementarios. El primero examina si el IAV presenta un patrón dentro del año. Para aislarlo se compara el valor de cada trimestre con el promedio anual de su propia provincia, un control necesario para no confundir el efecto estacional con la tendencia de fondo. El resultado, recogido en la Figura 2, es un patrón de magnitud reducida pero sistemático: el primer trimestre se sitúa un 2,180 % por debajo del promedio anual y el cuarto un 1,246 % por

encima, con una progresión ascendente a lo largo del año. Esta regularidad justifica que, en el capítulo 3, el trimestre se codifique de una forma especial que preserve su naturaleza cíclica, de modo que el modelo entienda que el cuarto trimestre y el primero del año siguiente son consecutivos.




Figura 2. Desviación del IAV respecto al promedio anual de cada provincia

El segundo análisis recalcula el indicador utilizando por separado el salario masculino y el femenino, manteniendo el mismo precio de vivienda. Como el precio es idéntico para ambos, cualquier diferencia procede exclusivamente de la desigualdad salarial. El resultado, representado en la Figura 3, es una brecha considerable: el IAV medio fue de 5,294 años para los hombres frente a 6,638 para las mujeres, una diferencia de 1,344 años, que equivale a un 25,405 % más de esfuerzo. Dicho de otro modo, una mujer necesita en promedio dieciséis meses adicionales de sueldo íntegro para adquirir la misma vivienda. La brecha se redujo de forma progresiva entre 2015 y 2024, del 27,871 % al 22,087 %, pero el IAV femenino permaneció por encima del masculino en todo el periodo sin excepción.




Figura 3. Evolución del IAV según el salario por sexo

Por último, conviene señalar una particularidad del *dataset* que se retomará más adelante. Algunas variables de publicación tardía, como la renta de los hogares, no están todavía disponibles para 2024, ya que se publican con aproximadamente dos años de retraso. En esos casos se arrastra el último valor conocido de cada provincia, una decisión que reproduce exactamente la información de la que dispondría una herramienta en funcionamiento. Este procedimiento afecta a las 208 observaciones de 2024 y a otras 48 observaciones históricas, hasta alcanzar un total de 256 registros, que quedan identificados mediante una variable de control para poder evaluar posteriormente si influyen en la calidad de las predicciones.

3. Formulación del problema y preparación de los datos

Antes de construir ningún modelo es necesario transformar el conjunto de datos en un problema de predicción bien planteado y fijar las reglas con las que se evaluarán los resultados. Este capítulo aborda cuatro cuestiones: cómo se define aquello que se quiere predecir, qué información está realmente disponible en el momento de predecir, qué variables conviene conservar y cómo se mide de forma honesta la calidad de las predicciones.

3.1. Construcción del problema supervisado

Las revisiones del capítulo anterior no detectaron valores ausentes, ni duplicados, ni que se incumplieran los rangos básicos de coherencia. Por tanto, no fue necesario ni imputar valores, ni eliminar observaciones, ni corregir registros antes de la modelización. La preparación inicial se centró, en consecuencia, en ordenar el panel temporalmente y transformarlo en un conjunto de datos supervisado, es decir, uno en el que a cada observación se le asocia el valor que se pretende predecir.

El problema se planteó como una predicción con un horizonte de cuatro trimestres. Para cada provincia (p) y trimestre (t) de origen, se emplea la información disponible en ese momento para anticipar el IAV observado en la misma provincia un año después. Esa variable a predecir, denominada *IAV_objetivo_t4* en el código, se construyó ordenando las observaciones cronológicamente dentro de cada provincia y desplazando el *IAV_total* cuatro trimestres hacia el futuro.

Como consecuencia del horizonte seleccionado, las cuatro últimas observaciones de cada territorio no disponen de un valor de *IAV_objetivo_t4* observable dentro del periodo estudiado. Por tanto, se excluyeron 208 registros, cuatro por cada uno de los 52 territorios, obteniéndose un conjunto supervisado de 1.872 observaciones. Esta cifra se reducirá aún más al aplicar los retardos de disponibilidad que se describen en el apartado siguiente. Esta exclusión no responde a un problema de calidad de los datos, sino a la imposibilidad de observar el valor del indicador un año después del final de la serie.

3.2. Feature engineering

Bajo la denominación de *feature engineering* se agrupan las transformaciones que preparan las variables para que los modelos puedan aprender de ellas con la mayor eficacia posible. En este trabajo, la más importante de estas transformaciones no busca mejorar el rendimiento, sino garantizar el realismo de la predicción.

3.2.1. Disponibilidad real y creación de variables retardadas

La fecha a la que se refiere una observación no coincide con el momento en que esa información se publica. Una serie estadística correspondiente a un trimestre puede tardar meses, o incluso años, en estar disponible, como ocurre con la publicación de los salarios, entre otros. Esto produciría lo conocido como fuga de información: el modelo emplearía datos que en la práctica no existirían todavía en el momento de predecir, ofreciendo resultados excelentes sobre el papel, pero irreproducibles en un uso real.

Para evitarlo se adoptó un criterio de disponibilidad temporal, retardando cada variable según el calendario real de publicación de su fuente. Se distinguen tres grupos: las series de frecuencia trimestral, como los precios, el mercado laboral, la financiación o la actividad residencial, se incorporaron con un trimestre de retardo; las series demográficas anuales del INE, como la población, la estructura de edad o los hogares, se retardaron cuatro trimestres; y, finalmente, las series de publicación más tardía, el salario de la AEAT y la renta de los hogares del INE, se retardaron ocho trimestres.

Este último retardo merece una justificación detallada, porque condiciona todo el planteamiento. La AEAT publica los datos salariales de un ejercicio aproximadamente veintitrés meses después de su cierre. A modo de ejemplo, los datos correspondientes a 2025 están previstos para noviembre de 2026. Esto significa que, al predecir la accesibilidad de dentro de un año, el salario más reciente que se conoce corresponde a dos años atrás. La consecuencia es que, aunque el horizonte nominal de

predicción es de cuatro trimestres, el desfase efectivo entre la información disponible y el valor que se pretende anticipar alcanza los doce trimestres en el caso del salario.

Junto a los retardos se crearon tres variables temporales. En primer lugar, una tendencia cronológica que recoge la evolución de fondo a lo largo de los diez años analizados. En segundo lugar, dos transformaciones cíclicas del trimestre mediante las funciones seno y coseno. Introducir el trimestre como un simple número del 1 al 4 induciría al modelo a considerar que el cuarto trimestre y el primero del año siguiente están muy alejados, cuando en realidad son consecutivos. La codificación con seno y coseno preserva esa proximidad, de modo que el final de un año y el principio del siguiente queden representados como cercanos.

La creación del objetivo y de las variables retardadas reduce el número de observaciones disponibles, y conviene detallar cómo. De las 2.080 observaciones iniciales, la construcción del objetivo a cuatro trimestres elimina las 208 últimas de la serie, que carecen de valor futuro observable. La aplicación de los retardos de disponibilidad elimina a su vez las 416 primeras, que no disponen del historial suficiente para construir sus predictoras retardadas. El conjunto de modelización queda así en 1.456 observaciones, repartidas de forma perfectamente equilibrada en siete años objetivo, de 2018 a 2024, con 208 observaciones cada uno, y con periodos de origen comprendidos entre el primer trimestre de 2017 y el cuarto de 2023.

Estas 1.456 observaciones se reparten en dos grandes bloques según su año objetivo. El bloque de desarrollo, con 1.248 observaciones cuyo objetivo se sitúa entre 2018 y 2023, es el que se emplea para entrenar los modelos, seleccionar variables y ajustar los parámetros. El bloque de prueba, con las 208 observaciones cuyo objetivo es 2024, se reserva por completo para la evaluación final y no interviene en ninguna decisión previa. La forma concreta en que se subdivide el bloque de desarrollo para validar los modelos se detalla en el apartado 3.6.

3.3. Estructura de la variabilidad del IAV

Antes de seleccionar variables conviene entender de dónde procede la variabilidad del indicador. Para medirlo se emplea el estadístico η^2 , que indica qué proporción de la variabilidad total de una magnitud se explica por una variable categórica, en una escala de 0 a 1. Un valor próximo a 1 significa que esa variable, por sí sola, determina casi por completo el resultado.

El análisis, realizado sobre las observaciones disponibles hasta el año objetivo 2022, dentro del conjunto de desarrollo, excluyendo el periodo de validación más reciente y, especialmente, el conjunto de prueba de 2024, que permaneció completamente reservado para la evaluación final, arroja una conclusión contundente. La provincia explica el 98,6 % de la variabilidad del IAV futuro, frente al 82,6 % de la comunidad autónoma y apenas un 0,3 % del año. La accesibilidad a la vivienda en España es, ante todo, un fenómeno estructural de nivel territorial. Por lo tanto, saber en qué provincia se encuentra una observación determina casi por completo su valor, mientras que saber en qué año se sitúa apenas aporta información. El escaso valor del trimestre es coherente con el patrón intranual moderado identificado en el análisis exploratorio.

Este resultado por sí solo no basta para predecir, porque una previsión ingenua que repitiera el último valor conocido de cada provincia ya capturaría ese nivel. La pregunta relevante es otra: ¿explica el territorio también aquello en lo que esa previsión ingenua se equivoca? Para responderla se calcula el η^2 de la provincia no sobre el IAV, sino sobre el error de la referencia de persistencia. Esta referencia consiste en suponer que la accesibilidad dentro de un año será igual al último valor del indicador que puede calcularse con datos ya publicados. Como el salario se conoce con ocho trimestres de retraso, ese último valor disponible corresponde al IAV de ocho trimestres atrás. El resultado es que la provincia explica el 72,1 % de ese error. Dicho de otro modo, la previsión ingenua no se equivoca al azar, sino de forma sistemáticamente distinta en cada territorio, y esa regularidad es precisamente lo que un modelo puede aprender. Este hallazgo orienta toda la estrategia de los capítulos siguientes: el valor añadido no vendrá de anticipar mejor la tendencia general, sino de identificar qué características de cada provincia hacen que su accesibilidad se deteriore más deprisa o más despacio que la del conjunto.

3.4. Relación de los predictores con el objetivo

El estudio de la relación de cada predictor con la variable objetivo se realizó también sobre el conjunto de entrenamiento, empleando el coeficiente de correlación de Spearman. Este coeficiente mide si dos variables se mueven en el mismo sentido a partir del orden de sus valores, sin exigir que la relación sea lineal, lo que lo hace robusto frente a los valores extremos detectados en el análisis exploratorio. En todos los casos, este coeficiente se interpreta como una medida descriptiva de asociación y no como evidencia de causalidad.

La mayor relación con el objetivo corresponde al IAV disponible en el trimestre de origen, con un coeficiente de 0,980. Este valor tan elevado refleja la fuerte persistencia temporal del indicador y es precisamente lo que sustenta la referencia de persistencia. A continuación, destacan el valor tasado del metro cuadrado (0,834) y el importe medio de las hipotecas (0,646), ambos indicadores directos del nivel de precios.

Presentan asociaciones moderadas diversas variables demográficas y residenciales, como la proporción de población de 35 a 64 años (0,552), la población total (0,514) o el tamaño medio del hogar (0,513). En sentido contrario, la proporción de población de 65 años o más (-0,556) y la de hogares unipersonales (-0,530) muestran las relaciones negativas más fuertes con el objetivo, un patrón coherente con que el envejecimiento y la reducción del tamaño del hogar se concentren en las provincias del interior, que son las más accesibles. La Tabla 4 muestra todas las correlaciones restantes.

Estas correlaciones se emplean como una primera aproximación y no como un criterio definitivo de selección. Una relación individual reducida no implica necesariamente escasa capacidad predictiva, ya que una variable puede aportar información mediante relaciones no lineales o interacciones con otros predictores. Su utilidad definitiva se evaluará mediante los modelos y el análisis de ablación posterior.

3.5. Selección de variables

Con las predictoras candidatas disponibles, un procedimiento automático de selección aportaría poco y resultaría difícil de justificar. Se optó por una selección razonada, apoyada en el diagnóstico de redundancia entre variables y en la comprobación empírica de que la eliminación no degrada la capacidad predictiva.

El diagnóstico de multicolinealidad, que mide hasta qué punto una variable puede reconstruirse a partir de las demás mediante el factor de inflación de la varianza (*Variance Inflation Factor*, VIF), señaló como caso extremo la tasa de empleo. Al comprobarlo se verificó que esta se reconstruye a partir de la tasa de actividad y la de paro con un error medio de 0,003 puntos porcentuales. No se trata de una simple correlación elevada, sino de una identidad contable, ya que la proporción de ocupados es por definición el producto de la tasa de actividad por la proporción de activos que no están en paro. La variable se descartó por no aportar información nueva. El factor de inflación de la varianza de todas las predictoras, antes y después de la selección, se recoge en la Tabla 5 del anexo, donde se comprueba que el número de variables con VIF superior a 10 se reduce de 15 a 9.

El segundo criterio examinó los pares de variables con correlación muy elevada, conservando solo aquella conceptualmente más próxima al fenómeno estudiado. Bajo este criterio se descartó la renta mediana por unidad de consumo, redundante con la renta neta por hogar, ya que ambas proceden de la misma operación estadística, procedente del Atlas de Distribución de Renta de los Hogares del INE. Entre las dos se conservó la renta por hogar, por ser el hogar la unidad que toma la decisión de compra.

Otros pares con correlación elevada se conservaron íntegros por medir mecanismos distintos, decisión que conviene justificar porque algunos superan incluso a los descartados. El caso más llamativo es el del salario medio y la renta por hogar, con una correlación de 0,926, la más alta del conjunto. Se conservan ambos porque el salario recoge la retribución individual del trabajo, mientras que la renta por hogar incorpora todas las fuentes de ingreso del conjunto de convivientes, de modo que dos provincias con salarios idénticos pueden presentar rentas por hogar muy distintas. Del mismo modo se conservaron las plazas hoteleras y las pernoctaciones, que miden oferta

instalada y demanda efectiva, y el valor tasado junto con el importe medio de la hipoteca, que reflejan el precio del activo y la capacidad de endeudamiento que las entidades conceden sobre él. El conjunto de pares de variables con correlación *Spearman* superior a 0,80 se detalla en la Tabla 6 del anexo.

La comprobación empírica respaldó estas decisiones. Eliminar cualquiera de estas variables modificaba el error medio de validación en menos de cuatro milésimas, magnitud muy inferior a la variabilidad entre periodos, de modo que su conservación no penaliza la capacidad predictiva y preserva la interpretabilidad de los bloques temáticos en el capítulo 5. Conviene subrayar que la multicolinealidad no perjudica por igual a todas las técnicas, ya que afecta a la estabilidad de los coeficientes de los modelos lineales, pero apenas influye en los modelos basados en árboles, que seleccionan variables de forma individual.

3.6. Codificación y estrategia de validación temporal

Para adecuar el conjunto a las exigencias de los distintos algoritmos, las variables se sometieron a un tratamiento diferenciado. La provincia, única variable categórica, se transformó mediante codificación *one-hot*, que crea una variable binaria por cada territorio. Al existir 52 territorios se generaron 52 variables binarias, conservando la totalidad de las categorías sin omitir ninguna de referencia (*drop_first=False*). Esta decisión preserva la simetría en la posterior evaluación de la importancia de características.

Los predictores numéricos se prepararon en dos versiones: una estandarizada, con media cero y desviación típica uno, para los modelos sensibles a la escala, y otra con los valores originales para los modelos basados en árboles, que no requieren escalado. Todas las transformaciones se ajustaron exclusivamente con las observaciones de entrenamiento y se aplicaron después, sin recalcularlas, a las de validación y prueba, garantizando así que ninguna información de los periodos evaluados interviniera en la preparación.

La forma de evaluar los modelos debe respetar el orden cronológico, ya que entrenar con periodos posteriores al que se evalúa constituiría una fuga de información. Evaluar sobre un único periodo, además, resulta insuficiente, y el propio conjunto lo demuestra: el error de la referencia de persistencia oscila entre 0,292 años en el año objetivo 2024 y 0,165 en 2023, una variación que no responde a la calidad del método, sino a la casualidad de que el nivel medio del IAV de ciertos años se parezca más al de dos años atrás.

Para obtener una evaluación estable se adoptó una validación temporal expansiva. Bajo este esquema, para predecir cada año objetivo el modelo se entrena con la totalidad de los periodos anteriores, reproduciendo las condiciones reales de uso. Se emplearon como periodos de validación los años 2021, 2022 y 2023, exigiendo un mínimo de tres años de entrenamiento, cantidad necesaria para estimar los efectos de las 52 provincias. Finalmente, cabe recordar que la referencia de persistencia definida en el apartado 3.3, basada en el último valor disponible del indicador, constituye el umbral mínimo que cualquier modelo deberá superar para demostrar que las variables disponibles aportan información sobre la evolución futura. Debido al retardo del salario, ese valor corresponde al indicador de ocho trimestres atrás.

El año 2024 se reserva por completo y no interviene en ninguna decisión de diseño, selección de variables ni ajuste de los modelos. Solo se emplea en la evaluación final del capítulo 4, de modo que constituye una prueba genuinamente independiente sobre datos que el proceso de construcción nunca ha visto.

4. Modelización y evaluación

Este capítulo constituye el núcleo metodológico del TFM. En él se analizan y ajustan doce algoritmos de aprendizaje automático utilizando el conjunto de datos de entrenamiento, con el objetivo principal de compararlos y determinar cuáles logran superar la referencia de persistencia. La evaluación se realiza mediante la validación temporal expansiva descrita en el capítulo anterior, reservando el conjunto de prueba de 2024 para la evaluación final de la estrategia. A lo largo del capítulo, el análisis revelará dos conclusiones fundamentales: que el planteamiento metodológico

del problema resulta más decisivo que la propia elección del algoritmo, y que la selección de un único modelo ofrece una fiabilidad menor a la esperada.

4.1. Técnicas aplicadas y criterio de selección

Se evaluaron doce técnicas pertenecientes a cinco familias de algoritmos con supuestos teóricos y mecanismos de aprendizaje distintos. Esta diversidad responde a una estrategia deliberada, fundamentada en que ninguna técnica es intrínsecamente superior a las demás en todos los escenarios y en que, como se demostrará, la familia a la que pertenece el algoritmo interactúa de forma determinante con la manera de formular el problema.

- 1) **Modelos lineales (regresión lineal, Ridge y Elastic Net):** explican el indicador (IAV) como una combinación lineal de las variables explicativas y presentan la propiedad estructural de poder extrapolar fuera del rango de valores observado en el entrenamiento.
- 2) **Modelos basados en distancia, representados por los k vecinos más próximos (K-Nearest Neighbors, KNN):** estiman las predicciones a partir del promediado de las observaciones más cercanas en el espacio de características.
- 3) **Máquinas de vectores de soporte para regresión (Support Vector Regression, SVR):** proyectan los datos sobre espacios de mayor dimensión para capturar relaciones no lineales complejas.
- 4) **Redes neuronales, representadas por el perceptrón multicapa (Multilayer Perceptron, MLP):** son aproximadores universales capaces de modelar patrones no lineales mediante capas de neuronas interconectadas.
- 5) **Modelos basados en árboles:** dividen sucesivamente el espacio de características (variables) para capturar interacciones complejas, pero se agrupan en tres tipos según cómo se utilicen los árboles. El árbol de decisión individual (*Decision Tree*) es el componente básico, sencillo de interpretar, pero inestable. Los métodos de promediado o *bagging* (*Random Forest* y *Extra Trees*) construyen numerosos árboles en paralelo sobre muestras distintas de los datos y promedian sus predicciones, lo que reduce la inestabilidad del árbol individual. Por último, las variantes de potenciación del gradiente o *boosting* (*Gradient Boosting*, *HistGradientBoosting* y *XGBoost*) construyen los árboles de forma secuencial, de modo que cada uno corrige los errores cometidos por los anteriores.

Con el objetivo de garantizar el rigor metodológico, todas las técnicas sensibles a la escala de las variables se integraron en un flujo de trabajo (*pipeline*) que estandariza los datos empleando exclusivamente la información de entrenamiento de cada pliegue (*fold*). De este modo, se asegura que ninguna información de los periodos evaluados intervenga en las transformaciones, previniendo cualquier sesgo de fuga de datos (*data leakage*).

4.2. Dos formulaciones del problema de aprendizaje

Un mismo objetivo admite planteamientos distintos, y la elección entre uno de ellos condiciona los resultados tanto o más que la técnica empleada. En este sentido, se compararon dos formulaciones:

- **Formulación directa:** el modelo aprende a predecir el valor del IAV a cuatro trimestres vista, debiendo reproducir por sí solo tanto el nivel estructural de cada territorio como su evolución.
- **Formulación de corrección:** el modelo aprende a predecir únicamente la diferencia entre el valor futuro y la referencia de persistencia, la cual se suma posteriormente a esta última. De este modo, el nivel territorial queda absorbido por la referencia y el modelo se concentra en aquello que la persistencia no captura (el residuo cuya estructura territorial se analizó en el capítulo 3). Esta formulación traslada al algoritmo un conocimiento del problema que se incorpora explícitamente mediante la definición del objetivo mismo: que el IAV es una magnitud altamente persistente y que la tarea útil no consiste en reconstruir su nivel, sino en anticipar su desviación.

Precisamente, la comparación entre ambas formulaciones constituye el hallazgo principal del capítulo, revelando un resultado que no era previsible, la formulación del problema y la familia de

algoritmos interactúan de forma sistemática, hasta el punto de mostrar un cambio importante en la clasificación del rendimiento de las técnicas.

Por un lado, en la formulación directa, el algoritmo KNN obtiene el menor error absoluto medio (MAE) con 0,146 años de salario, seguido de *Ridge* con 0,162. En cambio, los métodos de *ensemble* basados en potenciación (*boosting*) quedan muy por detrás, registrando errores superiores a los 0,26 años (peores incluso que la referencia de persistencia). Por otro lado, en la formulación de corrección, la jerarquía se invierte: *Gradient Boosting* encabeza la evaluación con un MAE de 0,147, seguido de *Extra Trees* y del resto de modelos basados en árboles, mientras que los modelos lineales pasan a situarse en la parte baja de la clasificación. Los resultados completos de ambas formulaciones se recogen en las Tabla 7 y Tabla 8, mientras que la Figura 4 presenta una síntesis gráfica de la comparación.




Figura 4. MAE medio de validación según la formulación del problema

El diagnóstico anterior permite interpretar este comportamiento. En el pliegue de 2023, Extra Trees bajo la formulación directa presenta un sesgo medio de +0,113 años, frente a los +0,014 de Ridge. Extra Trees construye sus predicciones mediante el promedio de las estimaciones de árboles cuyas hojas recogen valores medios del objetivo observados durante el entrenamiento. Este mecanismo limita su capacidad para extrapolar tendencias más allá de las particiones aprendidas. En consecuencia, la mayor sobreestimación observada resulta compatible con una menor adaptación al descenso del indicador en 2023, aunque el diagnóstico no permite atribuir la diferencia exclusivamente a este mecanismo. Los modelos lineales, en cambio, pueden utilizar el término de tendencia para proyectar con mayor flexibilidad la evolución temporal y extrapolar sin dificultad.

Al reformular el problema como una corrección sobre la persistencia, el nivel territorial deja de recaer exclusivamente sobre el modelo y pasa a estar aportado principalmente por la referencia. De esta manera, el aprendizaje se concentra en anticipar la desviación respecto a dicha referencia. En los resultados obtenidos, este planteamiento favorece a los modelos basados en árboles, capaces de capturar relaciones no lineales e interacciones entre las predictoras. Los modelos lineales, por el contrario, obtienen peores resultados que en la formulación directa, lo que indica que las especificaciones lineales evaluadas resultan menos adecuadas para predecir este residuo.

Finalmente, SVR y el perceptrón multicapa presentan los mayores errores de esta comparación inicial en ambas formulaciones. Estos resultados corresponden a las configuraciones evaluadas y no permiten descartar la utilidad de ambas técnicas para el problema. En el apartado 4.4 se examina si la optimización de sus hiperparámetros permite mejorar su capacidad predictiva.

4.3. Significación estadística de las diferencias

Comparar errores medios no resulta suficiente en este contexto. Una diferencia de apenas unas milésimas puede deberse al azar, por lo que presentarla como una mejora real sería incorrecto. Por esta razón, se aplicó el contraste de Diebold-Mariano, una prueba estadística diseñada para evaluar si dos métodos de predicción poseen la misma precisión esperada, teniendo en cuenta la autocorrelación de los errores en trimestres consecutivos. La hipótesis nula de la prueba establece

que ambos métodos presentan un rendimiento equivalente, de modo que el contraste determina si la diferencia observada es lo suficientemente amplia como para descartar la casualidad.

Este paso resulta especialmente pertinente en el presente trabajo, donde la referencia de persistencia es altamente competitiva y varias técnicas se sitúan a escasa distancia entre sí. Al respecto, el contraste confirma que las diferencias más acusadas no son fruto del azar: seis de las veinticuatro combinaciones evaluadas mejoran la persistencia de forma estadísticamente significativa. Entre ellas destacan KNN en la formulación directa con un p -valor inferior a 0,001 y, en la formulación de corrección, *Gradient Boosting*, *Extra Trees*, *XGBoost* y *Random Forest*.

Asimismo, la prueba ofrece una lectura negativa de igual valor: algunas combinaciones que en apariencia mejoraban la referencia no logran superar el contraste. Es el caso de *HistGradientBoosting* en la formulación de corrección, cuyo p -valor (0,055) no permite afirmar que su ventaja sea estadísticamente significativa. Esta distinción justifica por sí sola la aplicación del contraste, dado que una comparación basada exclusivamente en el error medio habría considerado como logros ciertas diferencias que no resisten el rigor estadístico.

4.4. Optimización de hiperparámetros

Cabe señalar que los resultados presentados hasta ahora emplean las configuraciones por defecto de los algoritmos. Si bien este planteamiento resulta adecuado para una comparación inicial, puede penalizar de forma desigual a aquellas técnicas cuyo rendimiento depende críticamente del ajuste de sus parámetros (hiperparámetros). Por consiguiente, se optimizaron los modelos más destacados de cada formulación, junto con SVR y el perceptrón multicapa, con el fin de determinar si sus deficientes resultados iniciales obedecían a una configuración inadecuada o a una limitación metodológica estructural. Para ver las configuraciones de los hiperparámetros véase la Figura 22.

La búsqueda del espacio de hiperparámetros se realizó mediante un muestreo aleatorio (*Random Search*), utilizando la misma estructura de validación cruzada con ventanas temporales expansivas empleada anteriormente. Esta precaución resulta fundamental, puesto que el uso de un esquema de validación aleatorio no temporal habría permitido que la selección de hiperparámetros utilizase información del futuro, incurriendo en un sesgo de fuga de datos (*data leakage*).

Los resultados de este proceso mostraron ganancias muy desiguales entre modelos, y esa desigualdad resulta informativa:

- El perceptrón multicapa registró la mayor mejora de todo el catálogo, reduciendo su error un 38,2 % (de 0,257 a 0,159 años). Esto confirma que su deficiente desempeño inicial obedecía a un desajuste de parámetros y no a una incapacidad inherente del método, aunque se mantuvo aún distante de las alternativas más precisas.
- KNN obtuvo la segunda mayor mejora (11,6 %), alcanzando el mejor resultado global del capítulo con un MAE de 0,129 años de salario.
- Los conjuntos de árboles apenas experimentaron variaciones significativas, lo cual respalda su reconocida capacidad para ofrecer un elevado rendimiento sin necesidad de un ajuste fino exhaustivo.
- SVR, por el contrario, apenas mejoró un 0,8 % y se mantuvo como la alternativa menos precisa del catálogo, lo que pone de manifiesto una limitación de fondo del modelo ante este problema particular y no un mero problema de parametrización.

4.5. Bondades y debilidades de cada técnica

El comportamiento observado a lo largo del capítulo permite caracterizar cada familia de algoritmos a partir de su rendimiento en este problema concreto, en lugar de recurrir a propiedades teóricas generales atribuidas de antemano.

Los modelos lineales, Ridge en particular, destacaron por su capacidad de extrapolar y seguir los cambios de tendencia, así como por la interpretabilidad de sus coeficientes. Sin embargo, no lograron aprovechar la estructura del residuo sobre la referencia de persistencia. KNN ofreció la

mejor precisión tras optimizar y un coste de cálculo despreciable. A pesar de ello, no extrapola fuera del rango observado ni proporciona métricas sobre la importancia de las variables. Los conjuntos de árboles resultaron excelentes en la formulación de corrección y muy robustos frente a la falta de ajuste, pero incapaces de acompañar los cambios de nivel en la formulación directa, además de tener un coste de cálculo elevado. Por último, SVR y el perceptrón mostraron un rendimiento pobre en este problema, con la particularidad de que el segundo dependía críticamente de su configuración inicial.

La conclusión transversal es que ninguna técnica resultó superior con independencia de cómo se planteara el problema. Un procedimiento automático que hubiera comparado las doce técnicas sobre una única formulación habría concluido que los conjuntos de árboles son inservibles para este problema, o que los modelos lineales lo son, en función de la formulación elegida de partida.

4.6. Ajuste definitivo y evaluación sobre 2024

Una vez seleccionadas las configuraciones óptimas, los modelos se reajustaron sobre la totalidad del conjunto de desarrollo, es decir, el periodo comprendido entre 2018 y 2023, y se evaluaron sobre 2024, el año reservado que no ha intervenido en ninguna decisión previa. Junto a las métricas de error habituales, se incorporó el R^2 intraprovincial, una versión del coeficiente de determinación calculada tras eliminar el nivel medio de cada territorio. Esta medida responde a una precaución necesaria: en un panel donde la variable provincia explica el 98,6 % de la variabilidad del indicador, un R^2 convencional elevado reflejaría tan solo la capacidad de distinguir unas provincias de otras, algo que cualquier método consigue, y no la capacidad real de anticipar la evolución temporal dentro de cada territorio.

La evaluación final sobre el conjunto de prueba arroja un resultado que conviene exponer con franqueza: la jerarquía de modelos obtenida en la fase de validación no solo no se traslada al año 2024, sino que se invierte. En efecto, la correlación de rangos entre el error de validación y el de prueba es de -0,847. Los modelos que ocuparon las primeras posiciones en validación pasaron a situarse en las últimas sobre 2024, mientras que las alternativas con peor desempeño inicial (*Ridge* y SVR) resultaron ser las más precisas. Este fenómeno constituye una manifestación clara de la llamada *maldición del ganador*, en la que el modelo con mejor resultado en validación suele ser también aquel cuya ventaja competitiva se apoyaba en particularidades específicas de los periodos evaluados.

El mecanismo explicativo subyacente se evidencia al examinar el error trimestre a trimestre. En el caso de KNN, el error crece de forma continuada a lo largo de 2024, desde 0,054 en el primer trimestre a 0,432 en el cuarto. Este deterioro responde a que, al generar predicciones mediante promedios de observaciones vecinas, la técnica no puede superar los valores límites presentes en el conjunto de entrenamiento, coincidiendo con el hecho de que 2024 registró el mayor incremento del IAV de toda la serie histórica. Por el contrario, *Ridge* mantuvo un error prácticamente constante gracias a su término de tendencia explícito, el cual le permite proyectar el crecimiento en lugar de quedar anclado a los niveles pasados. Este contraste de comportamiento se aprecia con claridad en la Figura 5.




Figura 5. Evolución trimestral del MAE sobre el conjunto de prueba (2024)

No obstante, es fundamental destacar un aspecto positivo de gran relevancia: las siete configuraciones evaluadas mejoran la referencia de persistencia de forma estadísticamente significativa sobre el conjunto de prueba de 2024. Por consiguiente, la conclusión de que la aproximación propuesta aporta valor añadido no depende de la elección puntual de una técnica, sino que es una propiedad compartida por todos los modelos evaluados.

4.7. Selección del modelo y respuesta a la inestabilidad

Ante una ordenación de rendimiento que se invierte entre la fase de validación y la de prueba, la cuestión relevante no es cuál de los modelos individuales elegir, sino si tiene sentido elegir uno solo.

En primer lugar, conviene precisar que el procedimiento de selección en validación no fue defectuoso: los tres criterios habituales aplicables a estos datos (menor error medio, menor variabilidad entre periodos y mejor desempeño en el peor periodo) señalaban a KNN como la mejor opción. Por tanto, no existía fundamento empírico ni teórico para anticipar, con la información disponible en el conjunto de desarrollo, que *Ridge* resultaría ser la técnica superior en 2024.

En escenarios donde la selección individual muestra una elevada inestabilidad, la respuesta habitual en la literatura de predicción no consiste en refinar el criterio de elección, sino en prescindir de la elección única mediante la combinación de predicciones de varios modelos. Este enfoque mitiga el riesgo de especificación sin necesidad de predecir de antemano qué modelo individual prevalecerá. En consecuencia, se optó por construir un promedio simple de las siete técnicas optimizadas, decisión adoptada estrictamente a partir de los patrones observados en la fase de validación y sin hacer uso de la información del año reservado.

El rendimiento del modelo combinado supera ampliamente las expectativas:

- **Precisión global:** sobre el conjunto de prueba de 2024, el promedio de los siete modelos alcanza un MAE de 0,133 años de salario, superando la precisión de cualquiera de las técnicas individuales por separado (incluida *Ridge*, que figuraba como la mejor *a posteriori*).
- **Reducción del error:** su *skill score*, que mide la ganancia relativa respecto a la referencia de persistencia, se sitúa en el 54,4 %. En términos prácticos, la combinación reduce a más de la mitad el error de la alternativa trivial, fijando el error absoluto medio en el equivalente a 1,6 meses de salario y alcanzando un error porcentual inferior al 2 %.
- **Significación estadística:** el contraste de Diebold-Mariano confirma que esta mejora es altamente significativa, registrando un *p*-valor inferior a 0,001.

La razón por la que la combinación funciona tan bien se comprende al analizar los errores individuales: las distintas técnicas no cometen desviaciones en la misma dirección, sino que algunas infravaloran el crecimiento mientras que otras lo sobreestiman, permitiendo que el promedio cancele los sesgos de signo opuesto. Esta diversidad de predicción, que en el capítulo 5 se confirma al comprobar que los modelos se apoyan en variables distintas, es precisamente lo que la literatura identifica como la condición indispensable para que una combinación supere a sus componentes individuales.

En síntesis, las conclusiones del capítulo se resumen en dos pilares. Por una parte, el enfoque metodológico propuesto supera a la referencia de persistencia de forma estadísticamente significativa bajo todas las configuraciones evaluadas, demostrando que la mejora no depende de una elección circunstancial. Por otra, y más relevante, la selección de un único modelo resulta poco fiable con el volumen de datos disponible, resultando la combinación de predicciones en una solución más robusta que el refinamiento de los criterios de selección.

La Figura 6 ilustra esta segunda conclusión: el promedio de los siete modelos optimizados obtiene el menor MAE sobre el conjunto de prueba, por delante de la mediana, de los modelos individuales y de la referencia de persistencia.




Figura 6. MAE de los modelos candidatos sobre conjunto de prueba (2024)

Por todo ello, el promedio de los siete modelos optimizados se establece como la solución definitiva del trabajo, cuyo comportamiento interno se interpretará en el capítulo 5 y cuya implementación práctica se abordará en el capítulo 6.

5. Interpretación del modelo

Un modelo capaz de predecir con precisión resulta sustancialmente más útil si, además, es posible comprender cuáles son los factores en los que se apoya para generar sus estimaciones. Por ello, este capítulo analiza qué variables utiliza el modelo definitivo, con una advertencia metodológica que conviene mantener presente a lo largo de toda la lectura: las medidas de importancia que se presentan señalan asociación estadística y no relación de causalidad. En consecuencia, que una variable resulte determinante para la predicción no implica que una intervención directa sobre ella modifique de manera causal la accesibilidad a la vivienda.

5.1. Consideraciones previas y concordancia entre modelos

El modelo definitivo es un promedio de siete técnicas que pertenecen a familias de algoritmos distintas que, además, resuelven el problema bajo dos formulaciones diferentes. Esta circunstancia condiciona el análisis, porque no existe un procedimiento único que atribuya la predicción de un promedio de modelos heterogéneos a las variables de entrada. Los métodos habituales de interpretabilidad se definen sobre un modelo concreto. Se optó, por tanto, por interpretar los siete modelos por separado y examinar en qué medida coinciden.

Para medir la importancia de cada variable en cada modelo se empleó la importancia por permutación (*permutation feature importance*). Esta técnica consiste en desordenar al azar los valores de una variable en el conjunto de prueba y observar cuánto empeora la predicción. Si al desordenarla el error apenas cambia, la variable era poco relevante, pero si el error se dispara, entonces, sí era determinante.

El resultado obliga a matizar cualquier conclusión sobre la importancia de las variables en cada modelo. La concordancia media entre las importancias de cada par de modelos, medida mediante el coeficiente de *Spearman*, es de apenas 0,068, es decir, prácticamente nula. Las únicas coincidencias apreciables se producen dentro de una misma familia algorítmica, como entre SVR y el MLP (0,502), o entre *Random Forest* y *Extra Trees* (0,299). Entre familias distintas, los modelos discrepan por completo. *Random Forest* atribuye el 62,8 % de su capacidad predictiva al valor tasado, mientras que el perceptrón le asigna un 0 % y concentra su atención en el tipo de interés. *Ridge*, por su parte, sitúa en primer lugar la proporción de población de nacionalidad española, variable que ningún otro modelo considera relevante. Esta falta de acuerdo se aprecia con claridad en la Figura 7, que representa el coeficiente de correlación de *Spearman* entre las importancias de todos los pares de modelos.




Figura 7. Concordancia (Spearman) entre las importancias de cada modelo

Esta divergencia explica retrospectivamente por qué la combinación planteada en el capítulo 4 resultó tan eficaz, ya que los modelos promediados eran internamente muy diversos. Asimismo, este hallazgo constituye una advertencia metodológica de alcance general: un trabajo que se hubiera limitado a interpretar únicamente el modelo con mejor resultado en validación habría concluido que la accesibilidad futura depende sobre todo de la identidad del territorio, mientras que seleccionar otro modelo habría llevado a atribuirle principalmente al precio de la vivienda o al tipo de interés. Las tres conclusiones son mutuamente incompatibles y, sin embargo, las tres estarían respaldadas por modelos con niveles de precisión equivalentes.

5.2. Aportación de cada bloque temático

Para obtener una perspectiva más estable y global que la ofrecida por los modelos individuales, se recurrió a un análisis de ablación (*ablation study*). Esta técnica consiste en retirar un bloque temático completo de variables explicativas, reentrenar el modelo combinado sin él y medir cuánto empeora la predicción. A diferencia de la permutación, que mide de qué se sirve un modelo ya entrenado, la ablación responde a una pregunta distinta: qué ocurriría si un bloque no hubiera estado disponible desde el principio, permitiendo que los modelos buscaran alternativas entre las variables restantes.

Los resultados de la ablación señalan dos bloques temáticos como imprescindibles:

- **Bloque financiero:** es el más decisivo con diferencia, hasta el punto de que su retirada duplica el error (MAE) del modelo, pasando de 0,133 a 0,275. Al examinarlo en detalle se comprueba que todo su peso recae en una única variable, el tipo de interés, cuya eliminación individual incrementa el error un 116,3 %. Este hallazgo merece especial atención, dado que el tipo de interés es una variable de ámbito nacional, idéntica para toda España en cada trimestre. Su función no puede consistir, por tanto, en explicar por qué unos territorios son menos accesibles que otros, sino en aportar la señal temporal común que fija el nivel general del indicador del año que se predice. Sin esa referencia sobre la dirección del mercado, el modelo pierde la referencia y el error se dispara.
- **Bloque territorial:** retirar los indicadores de provincia incrementa el error un 45,9 %, lo que confirma el papel estructural del territorio ya identificado en el capítulo 3.

El análisis de ablación revela también una aparente paradoja en el bloque financiero que ilustra la diferencia entre ambas medidas de importancia. Por un lado, la permutación le atribuía una importancia media reducida, ya que la mayoría de los modelos no lo utilizan. Por otro lado, la ablación lo señala como imprescindible. La explicación a esta discrepancia reside en el carácter combinado del modelo definitivo: solo dos de los siete modelos, SVR y MLP, se apoyan intensamente en el tipo de interés. Sin embargo, al retirar dicha variable del conjunto ambas técnicas se degradan de manera severa y arrastran consigo la precisión del promedio. La lección metodológica que se

extrae es que, en un modelo combinado, la importancia de una variable no equivale a la media de su importancia en los componentes individuales, basta con que un factor resulte crítico para un subconjunto de algoritmos para que se vuelva indispensable para la totalidad de la combinación. La distribución completa de la importancia por bloque temático en cada uno de los siete modelos se recoge en la Tabla 9 del anexo.

5.3. Refutación de la hipótesis sobre la presión turística

Las variables de presión turística, las plazas hoteleras y las pernoctaciones, se incorporaron al conjunto de datos durante su construcción bajo una justificación teórica explícita. Los mayores errores de las versiones preliminares del trabajo se concentraban en provincias como Málaga o Illes Balears, áreas donde la tensión que la actividad turística ejerce sobre el mercado residencial constituye un fenómeno ampliamente documentado y de naturaleza eminentemente provincial. Cabía esperar, por tanto, que estas variables contribuyeran a mejorar la capacidad predictiva en dichos territorios.

Sin embargo, los resultados no respaldan esa hipótesis. Retirar el bloque de presión turística deja el error prácticamente inalterado. El análisis restringido a los territorios donde este mecanismo debería operar es aún más concluyente: con y sin las variables turísticas, el error coincide hasta la tercera cifra decimal, tanto en las provincias turísticas como en el resto. Por consiguiente, ambas variables resultan enteramente inertes para el modelo.

Por tanto, la conclusión adecuada no es que el turismo carezca de influencia sobre la accesibilidad residencial, sino que las plazas hoteleras y las pernoctaciones no capturan ese mecanismo de forma útil para la predicción. Ambas variables miden la actividad hotelera tradicional, omitiendo la oferta de viviendas de uso turístico (VUT) en el mercado residencial, la cual representa probablemente el canal principal a través del cual la presión turística se traslada al precio de compraventa. Se trata de una hipótesis con fundamento teórico que, tras ser contrastada empíricamente, no resulta confirmada. Un resultado desfavorable que, lejos de ser un fallo, constituye un hallazgo legítimo de la investigación y se recoge como tal.

Por último, conviene precisar la razón metodológica por la cual estas variables se conservaron en el conjunto definitivo. El análisis de ablación se ejecutó sobre el conjunto de prueba correspondiente a 2024 (el periodo reservado para la evaluación final), por ende, utilizar sus resultados para redefinir *a posteriori* el espacio de características habría contaminado la evaluación objetiva, incurriendo en la misma lógica que se evitó al seleccionar el modelo. La simplificación del conjunto de variables se plantea, en consecuencia, como una línea de trabajo futura y no como una decisión adoptada en este trabajo.

5.4. Diferencias territoriales en la aportación del modelo

Si bien el análisis previo se enfoca en el conjunto global de los 52 territorios, la aportación de valor del modelo no se distribuye de manera uniforme sobre el territorio. Un examen desagregado por provincias permite identificar en qué ámbitos resulta más eficaz la herramienta y qué factores ejercen un mayor peso en cada caso.

La mejora sobre la persistencia se concentra en territorios que registraron cambios acusados en su nivel de accesibilidad. El modelo reduce el error de la persistencia en más de un 80 % en Melilla, Murcia, Ceuta, Segovia y Lugo, precisamente algunos de los territorios con mayor variación del indicador (IAV) durante el periodo. En cambio, empeora la persistencia en un reducido grupo de provincias, encabezado por Guadalajara e Illes Balears, donde la evolución reciente resultó especialmente volátil y compleja de anticipar. Este comportamiento heterogéneo es coherente con la naturaleza del problema: en mercados donde la accesibilidad se mantiene estable, la simple persistencia constituye un predictor difícil de superar, mientras que en escenarios de aceleración o cambio de tendencia el modelo aporta un valor añadido sustancial.

Por otro lado, la evaluación del factor más determinante en cada territorio confirma, desde otra perspectiva, la conclusión del apartado 5.2. Al calcular en cada provincia qué bloque temático deteriora más la predicción cuando se retira, el bloque financiero resulta ser el más dominante en 46 de los 52 territorios, seguido a mucha distancia por el mercado residencial, decisivo en solo cinco

territorios. Esto refuerza la idea de que el tipo de interés, pese a ser una variable idéntica para toda España, constituye el ancla temporal que el modelo requiere para ubicar la tendencia del indicador en casi cualquier territorio, siendo su ausencia lo que más perjudica a la predicción con independencia de la provincia considerada.

6. Productivización

Uno de los objetivos del trabajo era que el modelo no quedara como un ejercicio analítico, sino que pudiera utilizarse de forma equivalente a una herramienta empresarial, en la que se introduzcan datos nuevos y se obtenga una predicción. Con este fin se desarrolló una aplicación web interactiva que traduce los resultados del modelo en información aplicable a la toma de decisiones. La aplicación se organiza en tres módulos.

El primero es un mapa territorial que representa la predicción del IAV para 2025 en cada uno de los 52 territorios utilizando una escala de color que distingue las provincias más accesibles de las más tensionadas. Al seleccionar una provincia, el usuario visualiza el IAV estimado, su interpretación en años de salario, el precio de la vivienda previsto, la comparación con el valor del año anterior y, además, muestra un intervalo de incertidumbre para cada predicción, obtenido de la dispersión entre los siete modelos que componen el conjunto.

El segundo módulo es un simulador de compra adaptado a las circunstancias del usuario. A partir de información como sus ingresos, sus ahorros y la superficie buscada (tamaño de la vivienda), y aplicando los criterios habituales de concesión de las entidades financieras, el simulador determina en qué provincias resulta accesible una vivienda con su situación particular, distinguiendo entre la compra con hipoteca y la compra al contado.

El tercer módulo es un simulador de política monetaria que constituye el mejor ejemplo de productivización del modelo. El usuario modifica el tipo de interés hipotecario y los siete modelos vuelven a ejecutarse con ese valor, devolviendo una previsión nueva para los 52 territorios. Este módulo no consulta resultados almacenados, sino que emplea el modelo en tiempo real para responder a una pregunta de negocio: qué ocurriría con la accesibilidad si el Banco Central Europeo endureciera o relajara su política monetaria. Su relevancia se apoya directamente en el capítulo 5, donde el tipo de interés se identificó como la variable de la que más depende el modelo.

El funcionamiento detallado de la aplicación, las instrucciones de ejecución y varios casos de uso se presentan mediante capturas en el [anexo](#).

7. Conclusiones, limitaciones y propuestas de mejora

Este capítulo resume los hallazgos clave derivados del trabajo realizado, destacando sus aspectos más significativos. Además, se presentan las limitaciones de este proyecto y se proponen nuevas direcciones de investigación y desarrollo que podrían optimizar los resultados obtenidos o abrir nuevas áreas de estudio.

7.1. Conclusiones

El presente trabajo se estructuró con el objetivo de responder a una pregunta fundamental: ¿es posible anticipar, con un año de antelación y de forma fiable, el grado de accesibilidad a la vivienda en cada provincia española? Los resultados alcanzados permiten responder de manera afirmativa y con un margen de imprecisión notablemente reducido. Las principales aportaciones del TFM se sintetizan en los siguientes puntos:

- **Capacidad predictiva y precisión:** el sistema desarrollado predice la accesibilidad provincial sobre el conjunto de prueba de 2024 registrando un error absoluto medio (MAE) de apenas 1,6 meses de salario, lo que representa un error relativo inferior al 2 % respecto al valor real. En términos prácticos, si el modelo estima que en un territorio determinado se requieren seis años de salario bruto íntegro para adquirir una vivienda, la cifra observada raramente se desvía más de unas pocas semanas respecto a dicha proyección. Esta

precisión convierte a la herramienta en un instrumento riguroso de apoyo para la toma de decisiones en administraciones públicas, entidades financieras y hogares.

- **Ganancia neta frente a la referencia de persistencia:** una aproximación elemental para estimar la accesibilidad futura consiste en asumir la continuidad del nivel presente en el IAV. Si bien esta alternativa trivial resulta competitiva debido a la naturaleza inercial del indicador, el enfoque propuesto reduce a más de la mitad su error, es decir, acierta con un margen que es menos de la mitad del que se obtendría suponiendo que nada cambia (una reducción del 54,4 %). Esta ganancia representa una mejora sustancial, cuya significación estadística se ha confirmado en el apartado 4.7 mediante una prueba específica, el contraste de Diebold-Mariano, que descarta que la mejora se deba al azar (p -valor $< 0,001$).
- **La lección más valiosa no fue técnica, sino de método:** durante el trabajo se descubrió que la formulación del problema, es decir, si se pide al modelo que prediga directamente la accesibilidad o únicamente cuánto se desviará de su valor reciente, importaba más que el algoritmo concreto que se eligiera. Y, sobre todo, se comprobó que confiar en un único modelo, por bueno que pareciera, era arriesgado, ya que, como ocurre con la maldición del ganador, el modelo que mejor rinde en las pruebas preliminares suele ser también el que más se ha ajustado a sus particularidades y el que peor se comporta ante datos nuevos. La solución fue no elegir un solo modelo, sino combinar varios y promediar sus previsiones, una estrategia que resultó ser más fiable que apostar por el favorito. Esta conclusión, que un procedimiento automático difícilmente habría alcanzado, es probablemente la aportación más transferible del trabajo a cualquier problema de predicción.
- **El tipo de interés como ancla temporal macroeconómica:** al analizar en qué se apoya el modelo para predecir, destacó un elemento por encima de todos: el tipo de interés de las hipotecas. Aunque es el mismo para toda España, resulta imprescindible porque marca la dirección general del mercado en cada momento. Cuando el dinero se encarece, comprar se vuelve más difícil en todas partes, y sin esa información el sistema pierde de vista hacia dónde se mueve la accesibilidad. Junto al coste de la financiación, el propio territorio es el otro gran determinante, ya que la localización geográfica sigue siendo el factor que más condiciona el acceso a la vivienda.
- **Una intuición razonable no siempre se confirma:** la hipótesis inicial que vinculaba la presión turística, medida mediante plazas hoteleras y pernoctaciones, con un mayor error en provincias tensionadas como Málaga o Illes Balears no resultó confirmada por los datos. Retirar dicho bloque mantuvo inalterada la precisión del modelo, lo que sugiere que la actividad hotelera reglada no capta la presión ejercida sobre el mercado residencial, la cual responde previsiblemente a la proliferación de viviendas de uso turístico (VUT). Reconocer que una hipótesis de partida no se confirma forma parte del rigor del análisis.

En conjunto, el trabajo demuestra que la accesibilidad a la vivienda puede anticiparse con utilidad práctica, y traduce ese resultado en una aplicación que permite consultar la previsión provincial, calcular la situación particular de cada usuario y simular el efecto de un cambio en los tipos de interés.

7.2. Limitaciones y líneas de trabajo futuras

A pesar de los resultados obtenidos, el estudio presenta una serie de limitaciones que condicionan su alcance.

La primera es la cantidad y el tipo de datos, ya que el estudio abarca diez años, un periodo que incluye acontecimientos excepcionales como la pandemia o la fuerte subida de los tipos de interés de 2022 y 2023, lo que podría alterar las relaciones que el modelo aprende. Además, la comprobación final se limita a un único año, 2024.

La segunda afecta al propio indicador de accesibilidad, el cual se mide como los años de salario bruto íntegro necesarios para comprar una vivienda de referencia de 80 m², una aproximación útil pero simplificada al no tener en cuenta otros factores que también pueden afectar a este indicador como el ahorro previo, la entrada exigida, el coste de la hipoteca o el resto de la renta del hogar, factores que sí condicionan la capacidad real de compra. La propia aplicación desarrollada trata de suplir esta carencia en su simulador personal, pero el indicador en sí sigue siendo una medida

general. Además, trabajar a nivel provincial oculta las diferencias internas, pues no es lo mismo comprar en una capital que en un municipio pequeño de la misma provincia.

La tercera se refiere a la disponibilidad temporal de las fuentes utilizadas. Las series estadísticas se publican con frecuencias y retrasos distintos, lo que obligó a homogeneizarlas y a estimar en qué momento estaría disponible cada dato, sin poder reconstruir con exactitud la información que existía en cada instante del pasado.

Por último, tal como se ha enfatizado a lo largo de la memoria, las técnicas de ML capturan asociaciones y patrones estadísticos en los datos, pero no identifican relaciones de causalidad. Por consiguiente, que una variable ayude a predecir no significa que actuar sobre ella modifique la accesibilidad residencial real.

De las limitaciones anteriores se derivan varias líneas de trabajo en las que el TFM podría ampliarse.

- 1) **Actualización del dataset y validación continua:** ampliar el horizonte temporal más allá de 2024 para controlar la degradación del modelo, detectar cambios estructurales, definir el momento de reentrenamiento e incluir intervalos de predicción para medir la incertidumbre.
- 2) **Enriquecimiento del indicador:** incorporar más variables financieras del hogar (renta neta, ahorro, esfuerzo hipotecario, precios del alquiler) y descender a escalas municipales para capturar la heterogeneidad intraprovincial.
- 3) **Exploración del papel de la vivienda turística de uso residencial:** quizás uno de los factores más relevantes del bloque de turismo que el presente trabajo no logró medir y que podría explicar mejor la situación residencial de los territorios más tensionados del país.

8. Bibliografía

- [1] Instituto Nacional de Estadística, «Índice de Precios de Vivienda (IPV). Base 2015. Cuarto trimestre de 2024,» 7 marzo 2025. [En línea]. Available: <https://www.ine.es/dyngs/Prensa/IPV4T24.htm>.
- [2] A. Lajer Baron, D. López-Rodríguez y L. San Juan, «El mercado de la vivienda residencial en España: evolución reciente y comparación internacional,» 16 octubre 2024. [En línea]. Available: <https://www.bde.es/wbe/es/publicaciones/analisis-economico-investigacion/documentos-ocasionales/el-mercado-de-la-vivienda-residencial-en-espana-evolucion-reciente-y-comparacion-internacional.html>.
- [3] Banco de España, «BExplora el mercado de vivienda,» [En línea]. Available: <https://www.bde.es/wbe/es/estadisticas/relacionados/visualizaciones-de-datos/estadisticas-economicas-generales/bexplora-el-mercado-de-vivienda/bexplora-el-mercado-de-vivienda.html>.
- [4] Ministerio de Vivienda y Agenda Urbana, «Valor tasado de la vivienda,» [En línea]. Available: <https://www.mivau.gob.es/el-ministerio/observatorios-y-estadisticas/estadisticas/valor-tasado-vivienda>.
- [5] Ministerio de Transportes y Movilidad Sostenible, «Obras en edificación: visados de dirección de obra de los Colegios de Arquitectos Técnicos,» [En línea]. Available: <https://www.transportes.gob.es/informacion-para-el-ciudadano/informacion-estadistica/construccion/obras-en-edificacion-visados-de-direccion-de-obra-de-los-colegios-de-arquitectos-tecnicos>.
- [6] Instituto Nacional de Estadística, «INEbase: lista completa de operaciones,» [En línea]. Available: <https://www.ine.es/dyngs/INEbase/listaoperaciones.htm>.

Anexos

Con el fin de mantener una extensión contenida en la memoria del TFM y evitar la saturación de código en el texto principal, todo el material del proyecto se encuentra disponible en un repositorio público de GitHub. Este incluye las fuentes de datos, los *scripts* que construyen el conjunto de datos, el *notebook* con el análisis completo y el código de la aplicación, junto con los *datasets* que cada *script* genera.

El repositorio se organiza en las siguientes secciones:

- Repositorio principal: https://github.com/rodridemarcos/TFM_MRBA
- Repositorio de [fuentes](#): contiene todas las series estadísticas que componen el *dataset*.
- Repositorio de [construcción_dataset](#): contiene tanto los *scripts* que generan el *dataset* para el análisis del TFM, como varios archivos auxiliares que describen la información de dichos *datasets*.
- Repositorio de [modelización](#): contiene el *notebook* con el análisis completo, comentado de forma más técnica, del *dataset* en formatos tanto .ipynb como .html.
- Repositorio de la [app](#): contiene el código y las predicciones que usa la herramienta interactiva.

I. Planificación temporal

El desarrollo del TFM se estructuró en las siguientes tareas:

- T1. Búsqueda de fuentes y *datasets*
- T2. Análisis y depuración de los *datasets*
- T3. Creación y validación del *dataset* definitivo
- T4. Análisis, modelización e interpretación
- T5. Desarrollo de la aplicación
- T6. Power Point y vídeo
- T7. Redacción, revisión y entrega de la memoria

A continuación, se presenta el diagrama de Gantt con la distribución temporal de las tareas realizadas durante el desarrollo del TFM, comprendido entre el 1 de julio y el 17 de septiembre. En cada celda se indica el número aproximado de horas dedicado semanalmente a cada actividad, obteniéndose una dedicación total estimada de 380 horas.

	1-7 julio	8-14 julio	15-21 julio	22-28 julio	29-4 agosto	5-11 agosto	12-18 agosto	19-25 agosto	26-1 sept	2-8 sept	9-17 sept
T1	40h	8h			10h						
T2		28h	18h	12h	8h						
T3					10h	32h	28h	4h			
T4								10h	20h		
T5									14h	24h	
T6										14h	8h
T7						14h	18h	28h	20h	10h	8h

Tabla 3. Diagrama de Gantt del tiempo dedicado al TFM

II. Licencias de uso de las fuentes de datos

El conjunto de datos original, el que genera el [Codigo_dataset_maestro.py](#), se construye íntegramente a partir de fuentes públicas oficiales, utilizándose exclusivamente con fines académicos y de investigación.

- **Fuentes públicas (INE, AEAT, Banco de España, Ministerio de Vivienda y Agenda Urbana):** constituyen la totalidad del *dataset*. Se rigen por la *Ley 37/2007 de reutilización de la información del sector público*, que permite su uso, comercial o no, siempre que se cite la fuente y la fecha de actualización y no se sugiera el respaldo explícito de dichos organismos.
- **Fuentes complementarias (Kaggle):** durante la fase preliminar de exploración se consultaron tres conjuntos de datos alojados en Kaggle relativos al mercado del alquiler (los de A. Lafe y L. Barreda, bajo licencia CC0 1.0 de dominio público (uso libre sin restricciones), y el de Techsalerator, bajo licencia Apache 2.0 (uso y modificación gratuitos manteniendo avisos de autoría). Estas fuentes sirvieron únicamente como referencia orientativa en las primeras etapas del trabajo y no se incorporaron al *dataset* maestro ni al definitivo, que se construyen exclusivamente con las fuentes oficiales mencionadas.

III. Código de generación del dataset del proyecto

El conjunto de datos empleado en este TFM se construye en dos etapas encadenadas, cuyo código completo se encuentra disponible en la carpeta de [construcción_dataset](#) del repositorio del proyecto en GitHub. La primera etapa integra las fuentes originales en un conjunto maestro amplio, y la segunda selecciona, transforma y reconstruye las variables hasta obtener el conjunto definitivo sobre el que se desarrolla el análisis.

i. Generación del conjunto maestro

La primera etapa la ejecuta el *script* [Codigo_dataset_maestro.py](#). Este proceso automatizado recorre las siete carpetas temáticas del repositorio ([Demografía](#), [Economía](#), [Mercado inmobiliario](#), [Mercado laboral](#), [Territorial](#), [Turismo](#) y [Vivienda](#)) disponibles en el directorio [fuentes](#) de GitHub, y lee de ellas dieciocho ficheros de datos procedentes en su totalidad de fuentes las fuentes oficiales mencionadas en el anterior anexo.

El *script* homogeneiza las distintas frecuencias y niveles de agregación de cada fuente, resuelve las diferencias de nomenclatura entre provincias y comunidades autónomas, y las integra sobre una estructura común de panel provincial trimestral mediante uniones controladas que verifican en cada paso la ausencia de duplicados y la conservación del número de filas. El resultado es el fichero [dataset_maestro_vivienda_trimestral_2015_2024_IAV.csv](#), que se compone por 2.080 observaciones, correspondientes a los 52 territorios españoles y los 40 trimestres del periodo 2015-2024, y 127 variables organizadas por bloques temáticos.

Además del *dataset* maestro, genera un fichero auxiliar llamado [auditoria_dataset_maestro.csv](#) que contiene una breve descripción de cada variable y su cobertura.

ii. Obtención del conjunto definitivo

La segunda etapa la ejecuta el *script* [construir_dataset_TFM_MRBA.py](#), que parte del conjunto maestro y de un fichero complementario, [fuentes_complementarias_provinciales.csv](#), ambos disponibles en el repositorio. Este segundo *script* realiza las operaciones que transforman el conjunto maestro en el conjunto definitivo del proyecto.

En esta etapa se seleccionan las variables con mayor relevancia analítica y mejor cobertura, descartando las redundantes y la disponibilidad insuficiente. Se reconstruye el precio de la vivienda mediante el encadenamiento del valor tasado de 2015 con la evolución del Índice de Precios de la Vivienda, según el procedimiento descrito en el apartado 2.2, y se calcula sobre esa base la variable objetivo del trabajo, el Índice de Accesibilidad a la Vivienda (IAV). Asimismo, se construyen las variables derivadas necesarias y se propagan las series de publicación tardía conforme al criterio de disponibilidad explicada en el capítulo 3.

El resultado es el fichero [dataset_TFM_MRBA.csv](#), el conjunto definitivo sobre el que se desarrolla todo el análisis, compuesto por 2.080 observaciones y 37 variables. Junto a él, el *script* genera el fichero [auditoria_dataset_TFM_MRBA.csv](#), que documenta para cada una de las 37 variables su bloque temático, descripción, unidad, tipo de valor, nivel de desagregación territorial y papel en el análisis, y que constituye la fuente de la Tabla 1 de la memoria.

IV. Bibliografía para el *dataset* maestro

Las fuentes recogidas a continuación corresponden a las operaciones estadísticas y conjuntos de datos empleados en la construcción del *dataset* original descrito en el anexo anterior. La numeración continúa la de la bibliografía de la memoria.

- [7] Banco de España, «Estadísticas económicas generales,» [En línea]. Available: <https://www.bde.es/webbe/es/estadisticas/temas/estadisticas-economicas-generales.html>.
- [8] Banco de España, «Boletín Estadístico. Capítulo 19,» [En línea]. Available: <https://www.bde.es/webbe/es/estadisticas/otras-clasificaciones/publicaciones/boletin-estadistico/capitulo-19.html>.
- [9] Banco de España, «Síntesis de Indicadores. Capítulo 1,» [En línea]. Available: <https://www.bde.es/webbe/es/estadisticas/otras-clasificaciones/publicaciones/sintesis-indicadores/capitulo-1.html>.
- [10] Banco de España, «Portal del Cliente Bancario. Tipos de referencia oficiales del mercado hipotecario,» [En línea]. Available: https://cliente.bancario.bde.es/pcb/es/menu-horizontal/productoservici/relacionados/tiposintereses/guia-textual/tiposinteresesrefe/tabla_tipos_referencia_oficiales_mercado_hipotecario.html.
- [11] Instituto Nacional de Estadística, «INEbase. Estadísticas por categoría,» [En línea]. Available: https://ine.es/dyngs/INEbase/categoria.htm?c=Estadistica_P&cid=1254735976607.
- [12] Instituto Nacional de Estadística, «Indicadores de renta media y mediana (tabla 53689),» [En línea]. Available: <https://www.ine.es/jaxiT3/Datos.htm?t=53689>.
- [13] Instituto Nacional de Estadística, «Encuesta de Población Activa. Tasas de actividad, paro y empleo por provincia y sexo (tabla 65349),» [En línea]. Available: <https://www.ine.es/jaxiT3/Datos.htm?t=65349>.
- [14] Instituto Nacional de Estadística, «Coyuntura turística hotelera. Viajeros y pernoctaciones por provincias (tabla 67190),» [En línea]. Available: <https://www.ine.es/jaxiT3/Tabla.htm?t=67190>.
- [15] Instituto Nacional de Estadística, «Establecimientos, plazas, grados de ocupación y personal empleado por comunidades autónomas y provincias,» [En línea]. Available: <https://www.ine.es/jaxiT3/Tabla.htm?t=2066>.
- [16] Instituto Nacional de Estadística, «Población según comunidad autónoma y provincia y sexo,» [En línea]. Available: <https://www.ine.es/jaxiT3/Tabla.htm?t=73024&L=0>.
- [17] Instituto Nacional de Estadística, «Indicadores demográficos,» [En línea]. Available: <https://www.ine.es/jaxiT3/Tabla.htm?t=53776>.

- [18] Instituto Nacional de Estadística, «Hogares de personas residentes en viviendas familiares por fecha y tamaño del hogar,» [En línea]. Available: <https://ine.es/jaxiT3/Tabla.htm?t=60133>.
- [19] Instituto Nacional de Estadística, «Sexo y sectores de actividad,» [En línea]. Available: <https://www.ine.es/jaxiT3/Tabla.htm?t=28192>.
- [20] Ministerio de Transportes y Movilidad Sostenible, «Boletín Estadístico Online. Vivienda y actuaciones urbanas,» [En línea]. Available: <https://apps.fomento.gob.es/BoletinOnline2/?nivel=2&orden=36000000>.
- [21] Ministerio de Transportes y Movilidad Sostenible, «Boletín Estadístico Online. Construcción,» [En línea]. Available: <https://apps.fomento.gob.es/BoletinOnline2/?nivel=2&orden=35000000>.
- [22] A. Lafe, «Rent prices Spain,» Kaggle, 2020. Licencia CC0 1.0 (dominio público). [En línea]. Available: <https://www.kaggle.com/datasets/alelafe/rent-prices-spain>.
- [23] Techsalerator, «Real estate and Airbnb data for the Spain,» Kaggle. Licencia Apache 2.0. [En línea]. Available: <https://www.kaggle.com/datasets/techsalerator/real-estate-and-airbnb-data-for-the-spain>.
- [24] L. Barreda, «Rental listings in Idealista Spain,» Kaggle, 2022. Licencia CC0 1.0 (dominio público). [En línea]. Available: <https://www.kaggle.com/datasets/laurabarreda/rental-listings-in-idealista-spain>.

V. App

Este anexo describe el funcionamiento de la aplicación web desarrollada para la puesta en uso del modelo. Se explica primero cómo ejecutarla y, a continuación, se recorren sus tres módulos mediante casos de uso ilustrados con capturas de pantalla.

- Ejecución de la app:

La aplicación está desarrollada con *Flask*, un marco de trabajo que despliega un servidor web local en el propio ordenador. Para ponerla en marcha, se procede del siguiente modo:

- 1) **Descargar la carpeta `app` completa del repositorio:** esta carpeta contiene el *script* principal de la aplicación, `app_TFM_MRBA.py`, junto con los tres archivos auxiliares necesarios para su ejecución: el modelo serializado (`modelo_TFM_MRBA.joblib`), las predicciones para 2025 (`predicciones_2025.csv`) y la matriz de entrada (`matriz_prediccion_2025.csv`). Estos tres archivos se generan en el capítulo 6 del notebook `Codigo_TFM_MRBA`, se exportan en un archivo comprimido .zip y posteriormente se descomprimen dentro de la carpeta `app`. Para que la aplicación funcione correctamente, los cuatro archivos deben permanecer en la misma carpeta.
- 2) **Configurar el entorno:** abrir el *script* principal en el entorno de desarrollo, en mi caso Spyder (se puede usar cualquiera que permita ejecutar formato .py), y establecer como directorio de trabajo la ruta donde se encuentra la carpeta.
- 3) **Ejecutar el *script*:** en la terminal aparecerá la dirección local del servidor. Copiar esa dirección, `http://127.0.0.1:5000`, en un navegador web.
- 4) **Interactuar:** probar las diferentes opciones que permite la app desde el navegador.
- 5) **Detener el servidor:** para detener la ejecución, pulsar Ctrl+C en la terminal de Spyder y cerrar la pestaña del navegador.

A continuación, se muestra la ejecución del *script* de la app en la terminal de Spyder:

```

In [1]: %runfile 'E:/UNIDAD USB/Máster/MÓDULOS/TFM/app/app_TFM_MRBA.py' --wdir
=====
APLICACIÓN DE ACCESIBILIDAD RESIDENCIAL – TFM
=====
Territorios cargados : 52
Modelos combinados   : 7
Año predicho         : 2025

Abra en el navegador: http://127.0.0.1:5000
Para detener la aplicación, pulse Ctrl+C en la consola.
=====
* Serving Flask app 'app_tfm_mrba'
* Debug mode: off
WARNING: This is a development server. Do not use it in a production deployment
Use a production WSGI server instead.
* Running on http://127.0.0.1:5000
Press CTRL+C to quit

```

Figura 8. Ejecución del script

La app se organiza en tres módulos (interfaces) accesibles desde las pestañas superiores: el mapa territorial, el simulador de compra y el simulador del efecto en los tipos de interés.




Figura 9. Pestaña superior de la app

A continuación, se describe cada uno de ellos:

- Módulo 1: Mapa territorial

El módulo inicial muestra la previsión del IAV para 2025 en los 52 territorios, representada mediante un mapa de calor en el que los tonos azules corresponden a los territorios más accesibles y los rojos a los más tensionados.

Paso 1: al abrir la aplicación, se muestra el mapa completo de España en dos modalidades distintas: mapa geográfico y mapa de mosaico. El usuario puede alternar entre ambas vistas mediante los botones situados en la parte superior.




Figura 10. Mapa de España geográfico y mosaico

Paso 2: al pasar el cursor sobre un territorio, el panel lateral muestra su información detallada: el IAV previsto para 2025, el intervalo de confianza derivado de la dispersión entre los siete modelos, el valor de 2024, la variación esperada, el precio previsto por metro

cuadrado y el salario medio. Al pulsar sobre un territorio, este queda fijado, de modo que su información permanece visible, aunque el cursor se desplace a otras zonas del mapa.



Figura 11. Información del territorio seleccionado

- Módulo 2: Simulador de compra personal

Este módulo traduce la previsión del modelo a la situación financiera particular del usuario, determinando en qué provincias resultaría accesible una vivienda con sus circunstancias. Reproduce los criterios habituales de concesión de las entidades financieras.

Paso 1: el usuario introduce sus datos financieros y selecciona la forma de compra. Si elige la compra con hipoteca, se solicitan los ingresos netos mensuales, las cuotas de otras deudas vigentes, el ahorro disponible y la superficie buscada.

Su situación financiera

El modelo predice el precio de la vivienda en cada territorio. Estos datos no intervienen en esa predicción: se aplican sobre ella para determinar dónde resulta accesible una vivienda con su situación financiera, siguiendo los criterios de concesión de las entidades.

Forma de compra	Superficie buscada (m²)	Salario bruto anual (€)	Ingresos netos mensuales (€)	Cuotas mensuales de otras deudas (€)
Con hipoteca	80	28000	1800	0

Ahorro disponible (€)	Referencia salarial territorial
45000	Media provincial

Figura 12. Formulario del simulador con hipoteca

Paso 2: la aplicación aplica los supuestos hipotecarios estándar (entrada del 20 %, gastos de compraventa del 10 %, plazo máximo de 30 años y un límite de endeudamiento del 30 % de los ingresos netos), todos ellos editables. A partir de la capacidad de pago y del ahorro disponible, calcula el precio máximo de vivienda que el usuario podría adquirir.

Supuestos hipotecarios

Estos valores reproducen los criterios habituales de concesión en España y son **supuestos de la aplicación**, no resultados del modelo. Las entidades exigen una entrada del 20% del valor del inmueble y no financian los gastos de compraventa, que rondan otro 10% en concepto de impuestos y formalización. El plazo máximo se sitúa en 30 años, con 35 de forma excepcional para compradores jóvenes. La cuota, sumada al resto de deudas vigentes, no debe superar el 30% de los ingresos netos, con un 35% como tolerancia máxima.

En obra nueva la entrada se abona de forma escalonada durante la construcción, mientras que en **segunda mano** debe disponerse del importe íntegro desde el primer día. La aplicación adopta el criterio más exigente, el de segunda mano.

Plazo (años, máximo 35)	Entrada (%)	Tipo de interés (%)	Endeudamiento máximo (% del neto)
30	20,0	3,2	30,0

Calcular

Figura 13. Supuestos hipotecarios editables

Paso 3: se obtiene el resultado por territorio. Para cada provincia se muestra el precio previsto de la vivienda buscada, el desembolso inicial necesario, la cuota mensual, el esfuerzo que representaría sobre los ingresos y si la compra resulta viable. En caso de no serlo, se indica el motivo concreto: ahorro insuficiente o superación del límite de endeudamiento.

Resultado por territorio

La entidad admitiría una cuota de hasta 540 € al mes, equivalente a un préstamo de 124.865 €. Su capacidad de pago permite una vivienda de hasta 156.081 € y su ahorro alcanza para 150.000 €, de modo que el límite efectivo es de 150.000 €.

34 de 52 territorios permiten adquirir 80 m². Los importes son medias provinciales e incluyen municipios pequeños, por lo que en las capitales serán superiores.

El **esfuerzo** es la proporción de sus ingresos netos mensuales que absorberían la cuota hipotecaria y el resto de deudas vigentes. El **desembolso inicial** es la suma de la entrada que no financia la entidad y de los impuestos y gastos de formalización, importe que debe estar disponible en el momento de la compra. Los **m² asequibles** indican la superficie máxima que podría adquirir en ese territorio con su capacidad de compra.

TERRITORIO	PRECIO M²	PRECIO VIVIENDA	DESEMBOLSO INICIAL	LE FALTA	CUOTA MENSUAL	ESFUERZO	M² ASEQUIBLES	SITUACIÓN
Ciudad Real	1023 €	81.846 €	24.554 €	—	283 €	15,7%	147 m²	Viable
Cuenca	1043 €	83.404 €	25.021 €	—	289 €	16,0%	144 m²	Viable
Cáceres	1052 €	84.162 €	25.249 €	—	291 €	16,2%	143 m²	Viable
Toledo	1055 €	84.427 €	25.328 €	—	292 €	16,2%	142 m²	Viable
Badajoz	1114 €	89.105 €	26.731 €	—	308 €	17,1%	135 m²	Viable
Barcelona	3266 €	261.277 €	78.383 €	33.383 €	904 €	50,2%	46 m²	Ahorro y renta insuficientes
Balears, Illes	3425 €	274.000 €	82.200 €	37.200 €	948 €	52,7%	44 m²	Ahorro y renta insuficientes
Bizkaia	3547 €	283.736 €	85.121 €	40.121 €	982 €	54,5%	42 m²	Ahorro y renta insuficientes
Madrid	3700 €	295.987 €	88.796 €	43.796 €	1024 €	56,9%	41 m²	Ahorro y renta insuficientes
Gipuzkoa	4016 €	321.256 €	96.377 €	51.377 €	1111 €	61,7%	37 m²	Ahorro y renta insuficientes

Figura 14. Resultado por territorio del simulador con hipoteca

Paso 4: si el usuario selecciona la compra al contado, el formulario se simplifica: desaparecen los datos de financiación y se solicita únicamente el presupuesto disponible. El resultado indica entonces en qué territorios alcanza ese presupuesto y qué superficie podría adquirir en cada uno.

Su situación financiera

El modelo predice el precio de la vivienda en cada territorio. Estos datos no intervienen en esa predicción: se aplican sobre ella para determinar dónde resulta accesible una vivienda con su situación financiera, siguiendo los criterios de concesión de las entidades.

Forma de compra

Superficie buscada (m²)

Salario bruto anual (€)

Presupuesto disponible (€)

Referencia salarial territorial

Al contado

80

28000

150000

Media provincial

Calcular

Figura 15. Modalidad de compra al contado

Resultado por territorio

Con un presupuesto de 150.000 € puede adquirir una vivienda de hasta 136.364 € una vez descontados los gastos de compraventa.

24 de 52 territorios permiten adquirir 80 m². Los importes son medias provinciales e incluyen municipios pequeños, por lo que en las capitales serán superiores.

TERRITORIO	PRECIO M²	PRECIO VIVIENDA	GASTOS	DESEMBOLSO TOTAL	LE FALTA	M² ASEQUIBLES	SITUACIÓN
Ciudad Real	1023 €	81.846 €	8185 €	90.030 €	—	133 m²	Viable
Cuenca	1043 €	83.404 €	8340 €	91.745 €	—	131 m²	Viable
Cáceres	1052 €	84.162 €	8416 €	92.578 €	—	130 m²	Viable
Barcelona	3266 €	261.277 €	26.128 €	287.405 €	137.405 €	42 m²	Presupuesto insuficiente
Balears, Illes	3425 €	274.000 €	27.400 €	301.401 €	151.401 €	40 m²	Presupuesto insuficiente
Bizkaia	3547 €	283.736 €	28.374 €	312.109 €	162.109 €	38 m²	Presupuesto insuficiente
Madrid	3700 €	295.987 €	29.599 €	325.586 €	175.586 €	37 m²	Presupuesto insuficiente
Gipuzkoa	4016 €	321.256 €	32.126 €	353.382 €	203.382 €	34 m²	Presupuesto insuficiente

Figura 16. Resultado por territorio del simulador con pago al contado

- **Modulo 3: Efecto de los tipos de interés**

Este módulo constituye el ejemplo más completo de puesta en uso del modelo, ya que no consulta resultados almacenados, sino que ejecuta el modelo en tiempo real ante una variación introducida por el usuario.

Paso 1: el usuario desplaza un control para modificar el tipo de interés hipotecario, entre dos puntos porcentuales por debajo y dos por encima del valor actual.




Figura 17. Control de variación del tipo de interés

Paso 2: al ejecutar la simulación, los siete modelos vuelven a calcular la previsión de los 52 territorios con el nuevo tipo de interés. La aplicación muestra el IAV medio resultante, su variación respecto de la previsión base y los territorios cuya accesibilidad se ve más afectada por el cambio.



Figura 18. Resultado de la simulación de tipos positivos de interés



Figura 19. Resultado de la simulación de tipos negativos de interés

Este módulo permite responder a una pregunta de naturaleza estratégica, como es el efecto que tendría sobre la accesibilidad a la vivienda un endurecimiento o una relajación de la política monetaria del Banco Central Europeo, y su relevancia se apoya en el hallazgo del capítulo 5, donde el tipo de interés se identificó como la variable más determinante del modelo.

VI. Figuras y tablas extra




Figura 20. Territorios con mayor y menor accesibilidad (2015-2024)




Figura 21. Variación del IAV entre 2015 y 2024 por territorio

	variable	rho con el objetivo	rho con el residuo
0	valor_tasado_m2_lag1	0.834	0.667
1	importe_medio_hipoteca_vivienda_eur_lag1	0.646	0.553
2	renta_neta_media_por_hogar_eur_lag8	0.366	0.497
3	salario_medio_anual_euros_total_lag8	0.201	0.387
4	pct_poblacion_espanola_lag4	-0.324	-0.364
5	ipv_general_lag1	-0.303	-0.362
6	pct_35_64_lag4	0.552	0.350
7	pct_65_mas_lag4	-0.556	-0.332
8	tasa_actividad_pct_total_lag1	0.321	0.330
9	pernoctaciones_por_habitante_lag1	0.262	0.310
10	tamano_medio_hogar_lag4	0.513	0.302
11	renta_mediana_por_unidad_consumo_eur_lag8	0.106	0.281
12	compraventas_por_1000_hab_lag1	0.321	0.274
13	pct_hogares_unipersonales_lag4	-0.530	-0.265
14	tasa_migracion_neta_exterior_por_1000_habitant...	0.282	0.251
15	tasa_empleo_pct_total_lag1	0.091	0.244
16	poblacion_total_lag4	0.514	0.221
17	plazas_hoteleras_por_1000_hab_lag1	0.068	0.161
18	visados_obra_nueva_por_1000_hab_lag1	0.169	0.152
19	pct_18_34_lag4	0.350	0.121
20	tasa_paro_pct_total_lag1	0.151	-0.087
21	tipo_interes_prestamos_vivienda_pct_lag1	-0.041	0.083
22	sen_trimestre	-0.055	-0.080
23	pct_compraventas_vivienda_nueva_lag1	0.016	0.053
24	indice_precios_consumo_base_2015_lag1	0.062	0.034
25	cos_trimestre	0.006	0.030
26	indice_costes_construccion_lag1	0.022	0.013
27	tendencia_temporal	0.063	-0.006

Tabla 4. Tabla de correlaciones de las predictoras con el objetivo

Variables con VIF superior a 10: 15 de 28		Variables con VIF superior a 10: 9 de 26	
	VIF		VIF
tasa_empleo_pct_total_lag1	974.390	pct_65_mas_lag4	65.990
tasa_paro_pct_total_lag1	508.784	pct_18_34_lag4	30.434
tasa_actividad_pct_total_lag1	438.824	plazas_hoteleras_por_1000_hab_lag1	25.027
pct_65_mas_lag4	71.442	pernoctaciones_por_habitante_lag1	21.552
renta_neta_media_por_hogar_eur_lag8	41.721	renta_neta_media_por_hogar_eur_lag8	21.220
renta_mediana_por_unidad_consumo_eur_lag8	39.807	salario_medio_anual_euros_total_lag8	19.347
pct_18_34_lag4	31.029		
plazas_hoteleras_por_1000_hab_lag1	25.373		
tamano_medio_hogar_lag4	24.675		
salario_medio_anual_euros_total_lag8	22.152		

Tabla 5. VIF antes y después de la selección

		rho
salario_medio_anual_euros_total_lag8	renta_neta_media_por_hogar_eur_lag8	0.926
tamano_medio_hogar_lag4	pct_hogares_unipersonales_lag4	0.896
pct_65_mas_lag4	tamano_medio_hogar_lag4	0.893
salario_medio_anual_euros_total_lag8	renta_mediana_por_unidad_consumo_eur_lag8	0.878
plazas_hoteleras_por_1000_hab_lag1	pernoctaciones_por_habitante_lag1	0.873
pct_18_34_lag4	pct_65_mas_lag4	0.869
renta_neta_media_por_hogar_eur_lag8	renta_mediana_por_unidad_consumo_eur_lag8	0.847
pct_65_mas_lag4	pct_hogares_unipersonales_lag4	0.836
importe_medio_hipoteca_vivienda_eur_lag1	valor_tasado_m2_lag1	0.830
pct_18_34_lag4	tamano_medio_hogar_lag4	0.818

Tabla 6. Pares de predictoras con correlación (Spearman) superior a 0,80

Modelo	MAE medio	Desviación entre pliegues	MAE 2021	MAE 2022	MAE 2023	Tiempo de ajuste (s)	Skill score (%)
KNN	0.146	0.011	0.154	0.154	0.131	0.008	25.535
Ridge	0.162	0.013	0.169	0.173	0.144	0.012	17.539
Extra Trees	0.175	0.007	0.180	0.180	0.164	2.255	10.979
Regresión lineal	0.195	0.027	0.216	0.212	0.157	0.015	0.758
Elastic Net	0.210	0.053	0.190	0.158	0.282	0.027	-6.970
Gradient Boosting	0.262	0.024	0.278	0.281	0.228	2.624	-33.568
Random Forest	0.290	0.019	0.299	0.308	0.263	4.771	-47.713
Árbol de decisión	0.322	0.009	0.310	0.331	0.324	0.038	-63.759
XGBoost	0.324	0.022	0.331	0.347	0.294	0.683	-64.927
HistGradientBoosting	0.332	0.040	0.344	0.374	0.277	0.484	-69.012
SVR	0.553	0.188	0.469	0.377	0.813	0.059	-181.711
MLP	0.696	0.391	0.490	0.355	1.244	2.225	-254.512

Tabla 7. Resultados formulación directa

Modelo	MAE medio	Desviación entre pliegues	MAE 2021	MAE 2022	MAE 2023	Tiempo de ajuste (s)	Skill score (%)
Gradient Boosting	0.147	0.013	0.154	0.129	0.159	2.665	24.995
Extra Trees	0.154	0.045	0.143	0.105	0.214	2.846	21.551
XGBoost	0.160	0.041	0.145	0.119	0.216	0.584	18.382
Random Forest	0.164	0.042	0.161	0.114	0.216	5.084	16.598
HistGradientBoosting	0.167	0.028	0.163	0.135	0.204	0.481	14.820
Árbol de decisión	0.184	0.033	0.175	0.148	0.227	0.039	6.492
KNN	0.186	0.039	0.180	0.142	0.236	0.008	5.280
Ridge	0.202	0.022	0.191	0.233	0.182	0.024	-2.826
Regresión lineal	0.209	0.042	0.164	0.266	0.197	0.014	-6.320
Elastic Net	0.213	0.024	0.193	0.247	0.200	0.015	-8.577
SVR	0.219	0.105	0.131	0.160	0.367	0.060	-11.543
MLP	0.257	0.069	0.185	0.237	0.349	0.463	-30.909

Tabla 8. Resultados formulación de corrección

```

("Directa", "KNN"): {
    "kneighborsregressor__n_neighbors": [3, 5, 10, 15, 20, 30],
    "kneighborsregressor__weights": ["uniform", "distance"],
    "kneighborsregressor__p": [1, 2],
},
("Directa", "Ridge"): {
    "ridge__alpha": [0.1, 1, 10, 50, 100, 500],
},
("Corrección", "Gradient Boosting"): {
    "n_estimators": [200, 400],
    "learning_rate": [0.02, 0.05, 0.1],
    "max_depth": [2, 3, 4],
    "subsample": [0.7, 1.0],
},
("Corrección", "Extra Trees"): {
    "n_estimators": [300, 600],
    "max_depth": [None, 10, 20],
    "min_samples_leaf": [1, 2, 4],
    "max_features": [0.3, 0.6, 1.0],
},
("Corrección", "Random Forest"): {
    "n_estimators": [300],
    "max_depth": [None, 10, 20],
    "min_samples_leaf": [1, 2, 4],
    "max_features": [0.3, 0.6, 1.0],
},
("Corrección", "SVR"): {
    "svr__C": [1, 10, 100, 1000],
    "svr__epsilon": [0.01, 0.05, 0.1],
    "svr__gamma": ["scale", 0.01, 0.1],
},
("Corrección", "MLP"): {
    "mlpregressor__hidden_layer_sizes": [(32,), (64, 32)],
    "mlpregressor__alpha": [1e-4, 1e-2, 1],
    "mlpregressor__learning_rate_init": [1e-3, 1e-2],
},

```

Figura 22. Optimización de hiperparámetros

	KNN	Ridge	Gradient Boosting	Extra Trees	Random Forest	SVR	MLP	Media
Territorio	93.953	63.436	6.481	70.026	8.854	55.685	29.218	46.808
Mercado residencial y oferta	0.896	6.483	44.690	9.751	62.815	6.426	17.538	21.228
Demografía y hogares	0.201	20.623	40.265	20.001	27.538	7.039	8.007	17.668
Financiación	0.000	1.219	0.876	0.000	0.000	20.419	27.658	7.167
Mercado laboral y rentas	1.537	6.595	6.166	0.000	0.793	6.309	4.938	3.762
Temporal	3.388	0.619	0.800	0.000	0.000	0.093	5.232	1.448
Entorno económico	0.025	0.348	0.000	0.223	0.000	2.147	4.622	1.052
Presión turística	0.000	0.677	0.722	0.000	0.000	1.881	2.787	0.867

Tabla 9. Importancia relativa (%) de cada bloque temático por modelo